GRÁFICOS DE ANÁLISE DO MODELO

Avaliação do classificador de fraude com GMM semissupervisionado — painel de métricas, curva Precision–Recall, MCC por limiar, distribuição dos scores e matriz de confusão.

00 · Painel composto
01 · Precision–Recall
02 · MCC por limiar
05 · Distribuição dos scores
06 · Confusão por quadrante
Instruções para IA

PAINEL 00

Indicadores de desempenho e score composto

Quatro leituras rápidas: AP para ordenação de fraudes, MCC transformado para classificação, LogLoss transformado para avaliação probabilística e a média dos três critérios. Os valores são **simulados** e todos foram calculados com o mesmo conjunto de observações.

AP — Average Precision

Capacidade de identificar e ordenar fraudes em uma base desbalanceada.

AP

0,555

escala 0–1

Baseline PR: 0,036

Comparar com a prevalência de fraude.

MCC — Matthews Correlation Coefficient

Qualidade da classificação, considerando VP, VN, FP e FN.

(MCC + 1) / 2

0,761

escala 0–1



MCC bruto: 0,522

MCC transformado no limiar ótimo OOF.

LogLoss

Qualidade das probabilidades previstas; menor LogLoss é melhor.

$e^{-\text{LogLoss}}$

0,903

escala 0–1



LogLoss bruto: 0,102

Transformação para escala 0–1; maior é melhor.

Score composto

Síntese dos três critérios com pesos iguais.

$S = [AP + (MCC+1)/2 + e^{-\text{LogLoss}}] / 3$

0,740

escala 0–1



Três parcelas com peso 1/3

Score definido para comparação interna do projeto.

$$S = (AP + (MCC(\tau^*) + 1)/2 + e^{-LogLoss}) \ / \ 3 = \mathbf{0{,}740}$$



Vermelho → menor Amarelo → intermediário

Verde → maior

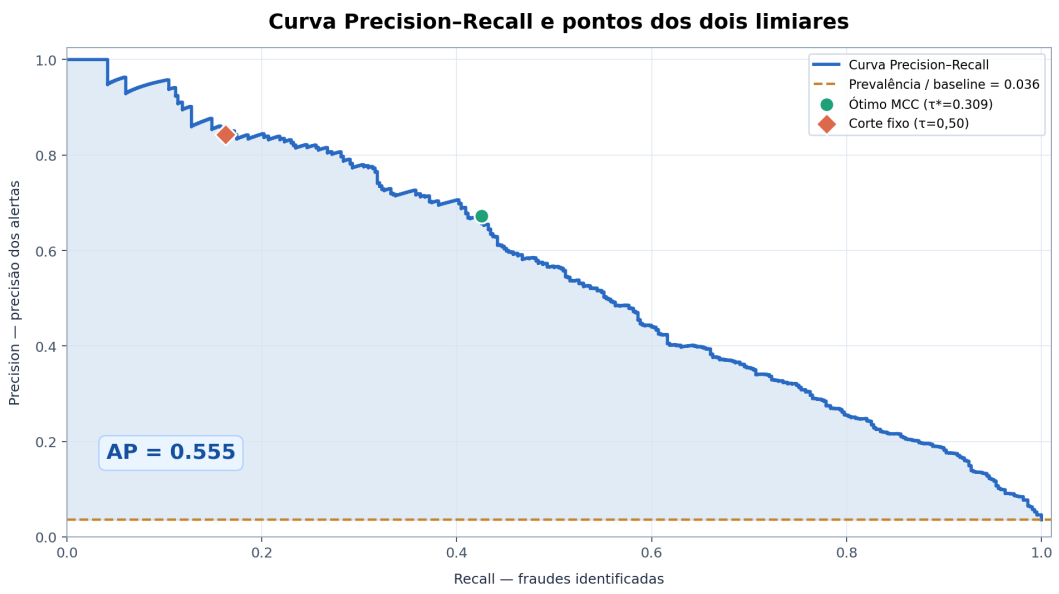
> **Interpretação:** o gradiente é uma referência visual relativa à escala 0–1, não uma classificação universal em “ruim”, “aceitável” ou “excelente”. Para fraude desbalanceada, compare AP com a prevalência (0,0358) e interprete LogLoss com um modelo de referência. No MCC transformado, 0,50 corresponde a MCC bruto = 0.

GRÁFICO 01

Curva Precision–Recall

Mostra a relação entre precisão e recall para vários limiares, destacando **Average Precision (AP)**, prevalência de fraude e as posições dos cortes **0,50** e **τ* ótimo pelo MCC**.

Curva Precision–Recall · Exemplo simulado



Uma única curva, pois AP e a curva PR não mudam quando se escolhe outro limiar: apenas o ponto de operação muda.

O que observar

Em bases desbalanceadas, a linha horizontal de referência é a prevalência de fraudes. A AP resume a precisão ponderada pelos incrementos de recall; seu valor não deve ser confundido com a área trapezoidal.

AP
0,555

Prevalência
0,0358

τ* ótimo MCC
0,309

Corte fixo
0,50

Precision em τ*

0,673

Recall em τ*

0,426

Precision em 0,50

0,843

Recall em 0,50

0,163

> **Leitura:** o corte ótimo pelo MCC não necessariamente maximiza AP ou Precision; ele seleciona um ponto na mesma curva PR.

Instruções para a próxima IA

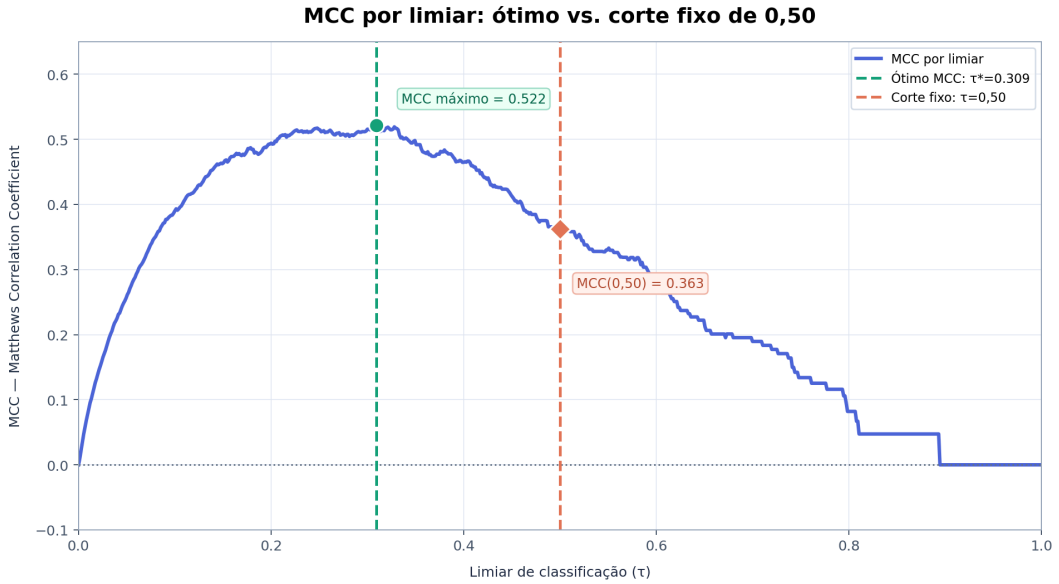
1. Usar os mesmos `y_true` e `risk_scores` OOF do projeto.
2. Gerar `precision_recall_curve` e calcular `average_precision_score`.
3. Adicionar linha de baseline horizontal em `mean(y_true)` e destacar o valor de AP.
4. Marcar os pontos de operação de `τ=0.50` e `τ=τ*` obtidos sobre os mesmos scores.
5. Usar classe positiva fraude = 1 e documentar a prevalência e a origem dos scores.

GRÁFICO 02

MCC por limiar

Mostra a variação do coeficiente de Matthews ao alterar o limiar de classificação. Devem aparecer sempre o **limiar ótimo selecionado nos OOF**, o MCC correspondente e a referência fixa de **0,50**.

MCC por limiar · Exemplo simulado



O MCC exibido aqui é bruto, na escala de −1 a +1. A transformação para [0,1] fica reservada ao painel do score composto.

Comparação obrigatória

τ* selecionado pelo MCC
0,309

MCC(τ*) bruto
0,522

τ fixo
0,50

MCC(0,50) bruto
0,363

Ao reduzir o corte, mais observações tendem a ser classificadas como fraude, mas o MCC pode aumentar ou diminuir conforme o balanço dos quatro tipos de resultado da matriz de confusão.

> **Seleção vs. avaliação:** em uma implementação real, τ* é selecionado usando OOF de treino e deve ser fixado antes da avaliação em teste independente. O MCC máximo observado na mesma amostra usada para escolher τ* é uma medida de seleção.

Instruções para a próxima IA

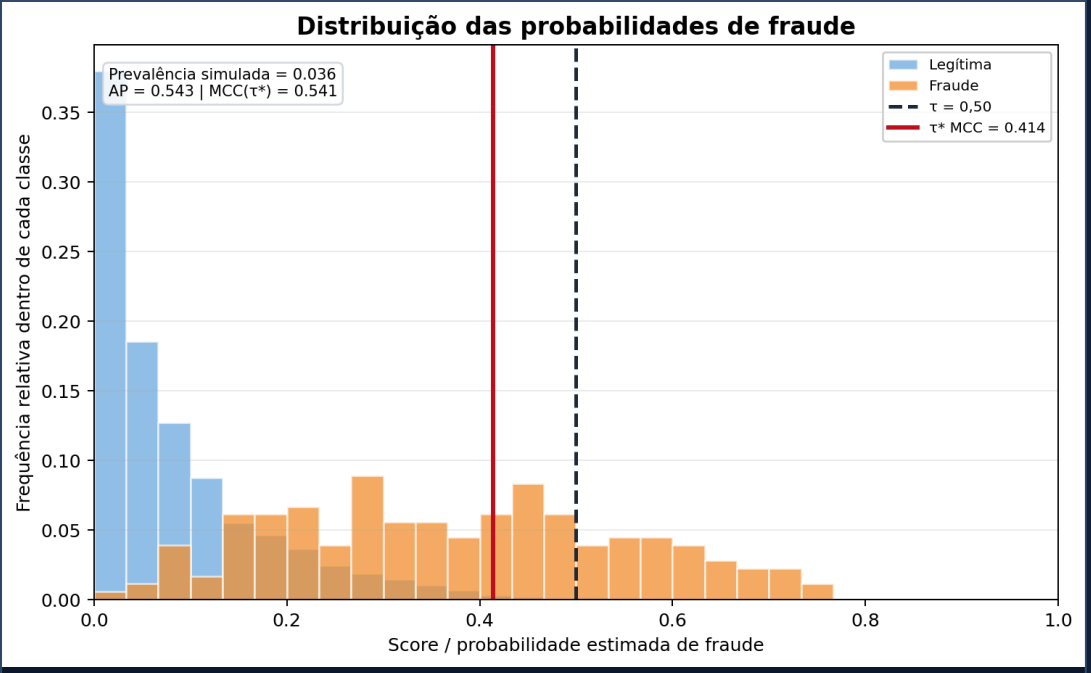
1. Construir uma grade de cortes ou usar todos os valores únicos de `risk_scores` OOF.
2. Para cada τ, calcular `matthews_corrcoef(y_true, risk_scores >= τ)`.
3. Destacar τ* que maximiza MCC, mostrar seu valor e o respectivo ponto.
4. Adicionar referência vertical em 0,50 e marcar MCC(0,50).
5. Usar **MCC bruto** no eixo Y; usar `(MCC+1)/2` somente no painel composto.
6. Exibir eixos, limites, origem dos dados e mesma política de decisão em todos os gráficos.

GRÁFICO 05

Distribuição das probabilidades de fraude

Histogramas das probabilidades estimadas para transações legítimas e fraudulentas. Este gráfico mostra **onde os scores se concentram**, quanta **sobreposição** existe entre as classes e como os cortes **τ*=MCC** e **0,50** interceptam as distribuições.

Scores de fraude por classe



As barras mostram a frequência relativa dentro de cada classe. A linha vermelha marca o limiar ótimo pelo MCC e a linha tracejada escura marca a referência fixa de 0,50.

O que este gráfico responde

- As fraudes tendem a receber scores maiores do que as transações legítimas?
- Em que região do score as duas classes mais se sobrepõem?
- O corte ótimo τ* está antes ou depois do corte fixo 0,50?
- Há concentração muito forte de scores perto de zero, sugerindo base altamente desbalanceada?

AP (mesma simulação)

0.543

τ* pelo MCC

0.414

MCC(τ*)

0.541

MCC(0,50)

0.426

Para o TCC, é útil normalizar separadamente cada classe para comparar os formatos das distribuições, sem esconder a sobreposição.

> **Leitura correta:** este gráfico não substitui a curva Precision–Recall nem o MCC por limiar. Ele mostra a *forma das distribuições* dos scores; os outros gráficos mostram desempenho de ordenação e desempenho de classificação.

GRÁFICO 06

Matriz de confusão detalhada por quadrante

Nesta versão, deixamos **somente a leitura detalhada por quadrante**. E ela deve aparecer **sempre em duplicidade**: um bloco para o **limiar ótimo pelo MCC** e outro para o **corte fixo em 0,50**. Cada bloco explica separadamente o que seria bom, médio ou ruim em **VN**, **FP**, **FN** e **VP**, com **mudança gradual de cor**.

Limiar ótimo pelo MCC

Leitura detalhada dos quadrantes usando o limiar selecionado pela varredura de MCC no OOF.

τ* = 0.414 **MCC = 0.541**

VN e FP somam 100% da classe legítima

99,25% / 0,75%

FN e VP somam 100% da classe fraude

55,56% / 44,44%

VN Verdadeiro negativo

99,25%

Percentual de transações legítimas corretamente classificadas como legítimas. Aqui alto é bom.



Ruim Médio Bom

Ruim (0%–85%)
Muitas transações legítimas estão sendo tratadas como suspeitas.

Médio (85%–97%)
Pode ser aceitável, mas ainda existe custo operacional relevante.

Bom (97%–100%)
Grande parte das legítimas está sendo corretamente liberada.

FP Falso positivo

0,75%

Percentual de transações legítimas classificadas como fraude. Aqui alto é ruim.



Bom Médio Ruim

Bom (0%–1%)
Baixo atrito para clientes legítimos.

Médio (1%–5%)
Pode ser tolerável dependendo da operação e dos ganhos em detecção.

Ruim (>5%)
Muitas legítimas estão sendo bloqueadas por engano.

FN Falso negativo

55,56%

Percentual de fraudes reais que passaram sem detecção. Aqui alto é ruim.



Bom Médio Ruim

Bom (0%–10%)
O modelo deixa escapar poucas fraudes.

Médio (10%–30%)
Desempenho intermediário; pode exigir ajuste de limiar ou modelo.

Ruim (>30%)
Muitas fraudes passam despercebidas.

VP Verdadeiro positivo 44,44%

Percentual de fraudes reais corretamente detectadas. Aqui alto é bom.



Ruim Médio Bom

Ruim (0%–40%)
O modelo detecta poucas fraudes.

Médio (40%–70%)
Há poder de detecção, mas ainda com espaço para melhora.

Bom (70%–100%)
Grande parcela das fraudes é identificada.

Corte fixo em 0,50

Leitura detalhada dos quadrantes usando a referência fixa τ = 0,50 para comparação.

τ = 0,50 MCC = 0.426

VN e FP somam 100% da classe legítima

99,71% / 0,29%

FN e VP somam 100% da classe fraude

75,00% / 25,00%

VN Verdadeiro negativo

99,71%

Percentual de transações legítimas corretamente classificadas como legítimas. Aqui alto é bom.



Ruim Médio Bom

Ruim (0%–85%)
Muitas transações legítimas estão sendo tratadas como suspeitas.

Médio (85%–97%)
Pode ser aceitável, mas ainda existe custo operacional relevante.

Bom (97%–100%)
Grande parte das legítimas está sendo corretamente liberada.

FP Falso positivo

0,29%

Percentual de transações legítimas classificadas como fraude. Aqui alto é ruim.



Bom Médio Ruim

Bom (0%–1%)
Baixo atrito para clientes legítimos.

Médio (1%–5%)
Pode ser tolerável dependendo da operação e dos ganhos em detecção.

Ruim (>5%)

Muitas legítimas estão sendo bloqueadas por engano.

FN Falso negativo

75,00%

Percentual de fraudes reais que passaram sem detecção. Aqui alto é ruim.



Bom Médio Ruim

Bom (0%–10%)
O modelo deixa escapar poucas fraudes.

Médio (10%–30%)
Desempenho intermediário; pode exigir ajuste de limiar ou modelo.

Ruim (>30%)
Muitas fraudes passam despercebidas.

VP Verdadeiro positivo

25,00%

Percentual de fraudes reais corretamente detectadas. Aqui alto é bom.



Ruim Médio Bom

Ruim (0%–40%)
O modelo detecta poucas fraudes.

Médio (40%–70%)
Há poder de detecção, mas ainda com espaço para melhora.

Bom (70%–100%)
Grande parcela das fraudes é identificada.

> **Importante:** as faixas bom/médio/ruim são **ilustrativas e contextuais**, mas a lógica qualitativa permanece: **VN e VP altos são desejáveis**, enquanto **FP e FN altos são indesejáveis**. Em fraude, aceitar um pequeno aumento de FP pode ser estratégico se isso reduzir fortemente os FN.

> **Regra para a outra IA:** este bloco deve ser gerado **sempre em par**: primeiro o painel do **MCC ótimo**, depois o painel do **corte 0,50**, usando os mesmos dados e a mesma normalização por classe real.

ESPECIFICAÇÃO TÉCNICA

Guia para a outra IA implementar os gráficos e painéis

Entradas esperadas

- `y_true` : rótulos, fraude = 1.
- `risk_scores` : probabilidades/scores de fraude [0,1] da mesma avaliação OOF.
- `τ*` : corte selecionado pela varredura de MCC nos OOF.
- `τ=0.50` : comparação fixa.

AP e LogLoss independem do limiar. MCC depende do limiar. Os gráficos 05 e 06 devem reutilizar exatamente a mesma amostra e os mesmos scores.

Regras visuais

- Reutilizar a mesma amostra, classe positiva e scores para garantir coerência numérica.

- Usar uma escala vermelho→amarelo→verde nos cards normalizados, com posição proporcional ao valor.
- Mostrar valores simulados como exemplos, sem atribuí-los ao TCC.
- Evitar tratar o score composto como métrica padronizada da literatura: é uma definição específica do projeto.

Referência de implementação em Python

```
from numpy import exp
from sklearn.metrics import (
    average_precision_score, precision_recall_curve,
    matthews_corrcoef, log_loss
)

# Os arrays devem corresponder aos mesmos índices OOF:
# y_true: 0 = legítima, 1 = fraude
# risk_scores: risco estimado pelo GMM, em [0, 1]
ap = average_precision_score(y_true, risk_scores)
precision, recall, thresholds_pr = precision_recall_curve(y_true, ri
ll = log_loss(y_true, risk_scores, labels=[0, 1])

# candidatos reais: valores únicos dos scores + referência 0,50
candidates = sorted(set(risk_scores) | {0.50})
results = [(t, matthews_corrcoef(y_true, risk_scores >= t))
           for t in candidates]
# Empate: escolher o maior limiar entre os empates do MCC
best_mcc = max(v for _, v in results)
tau_star = max(t for t, v in results if abs(v-best_mcc) <= 1e-12)
mcc_fixed = matthews_corrcoef(y_true, risk_scores >= 0.50)
mcc_trans = (best_mcc + 1) / 2
p_score = exp(-ll)
score_composto = (ap + mcc_trans + p_score) / 3
```

> **Nota importante:** estes gráficos ilustram uma única realização sintética, e não predições OOF reais do seu modelo. No pipeline, substituir pelos rótulos e scores da validação OOF; para

comparações finais de modelos, relatar também desempenho em avaliação independente quando disponível.

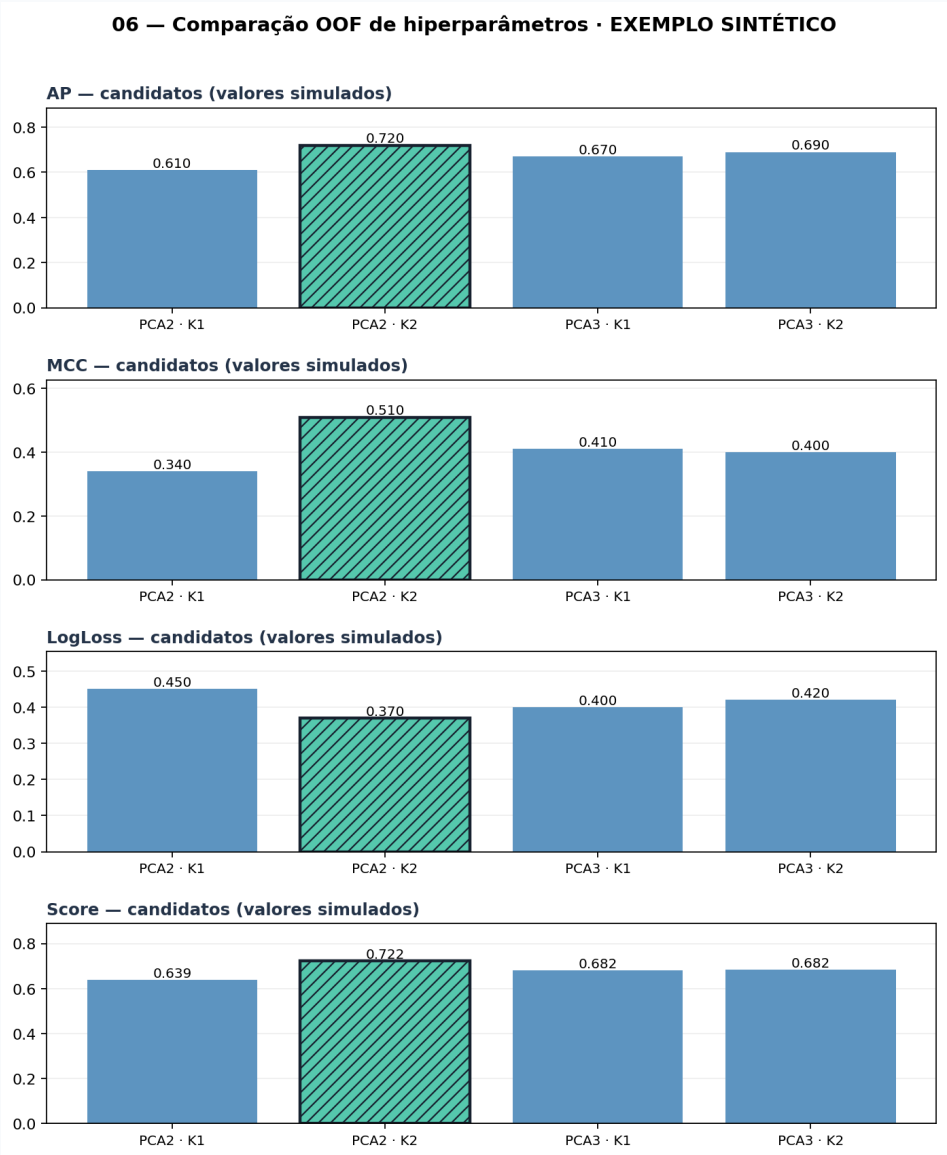
GRÁFICOS DE ANÁLISE DO MODELO · HTML offline · painéis, distribuição de scores e matriz de confusão com exemplos ilustrativos

GRÁFICO 06

Comparação de hiperparâmetros

A pipeline compara candidatos treinados e avaliados no desenvolvimento F1–F9.

São quatro painéis em escalas próprias: AP, MCC, LogLoss e score composto. O vencedor pode aparecer hachurado. A figura abaixo reproduz a organização implementada, com valores fictícios.



NUMERAÇÃO E PROVENIÊNCIA

Código e catálogo: equivalências

A nomenclatura original da matriz de confusão foi preservada; a numeração não foi renomeada no código.

CATÁLOGO ORIGINAL

O item 06 descreve a leitura de matriz de confusão por quadrantes nos cortes fixo e ótimo.
Os gráficos 00, 01, 02 e 05 mantêm seus significados previamente documentados.

IMPLEMENTAÇÃO ATUAL

03_matriz_confusao_05: matriz com limiar fixo 0,50.
04_matriz_confusao_mcc: matriz com τ^* determinado em OOF.
06_comparacao_hiperparametros: compara configurações e salva CSV da grade completa.

A figura do gráfico 06 mostra até maximo_configuracoes no PNG (25 na configuração analisada); o CSV contém todos os candidatos. Nenhuma métrica nem limiar utiliza F10 para selecionar o vencedor.