GRÁFICOS DE GMM

Catálogo visual e técnico para interpretação do Gaussian Mixture Model

GRÁFICO 01

Densidades marginais por dimensão

Visualização das densidades marginais dos componentes gaussianos e da mistura total. O número de painéis é igual ao número de dimensões efetivamente visualizadas: 1D → 1 marginal, 2D → 2 marginais, 3D → 3 marginais.

Descrição técnica

Este gráfico exibe apenas as **densidades marginais** ao longo de cada coordenada do espaço do GMM. Cada curva tracejada representa a contribuição marginal de uma gaussiana ponderada por seu peso π_k. A linha escura contínua representa a soma total da mistura.

$$f_j(t) = \Sigma_{k=1\ldots K}\ \pi_k \cdot \text{Normal}(t \mid \mu_{k,j},\ \Sigma_{k,jj})$$

Regras

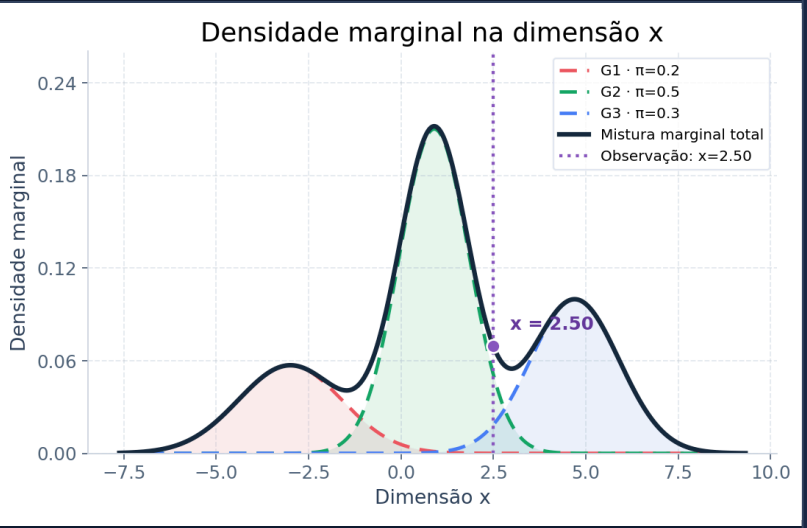
- 1D: mostrar somente a marginal em x.
- 2D: mostrar as marginais em x e y.
- 3D: mostrar as marginais em x, y e z.
- A densidade marginal não é probabilidade de fraude.
- Manter a mesma cor para cada gaussiana em todos os painéis.

EXEMPLO 1D

1D — uma marginal

Uma imagem para a dimensão x.

Marginal da dimensão x



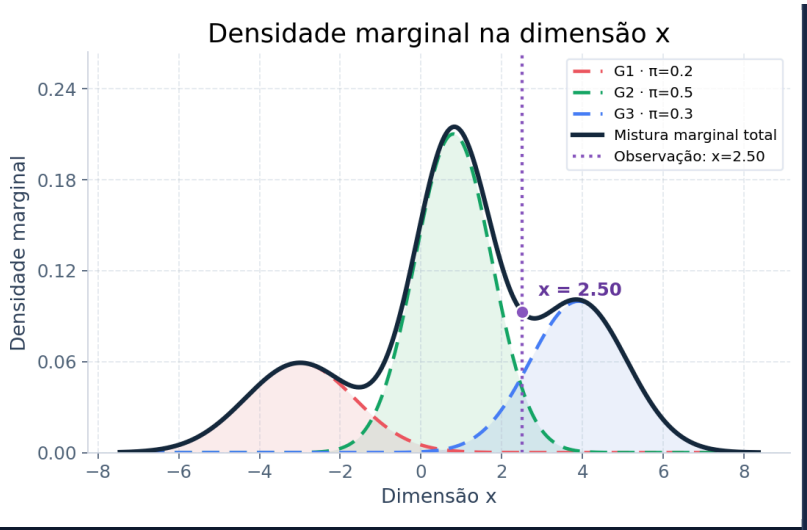
Distribuição marginal da dimensão x, com G1, G2, G3 e a mistura total.

EXEMPLO 2D

2D — duas marginais

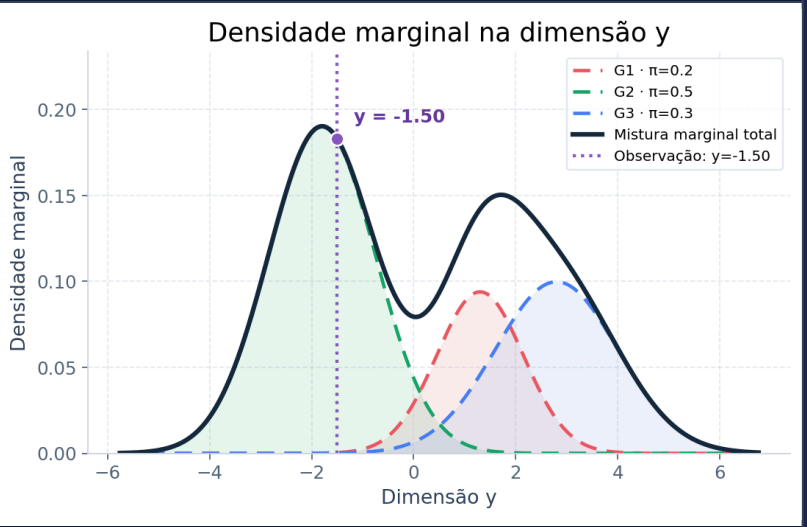
Duas imagens: marginal da dimensão x e marginal da dimensão y.

Marginal da dimensão x



Distribuição marginal em x no modelo 2D.

Marginal da dimensão y



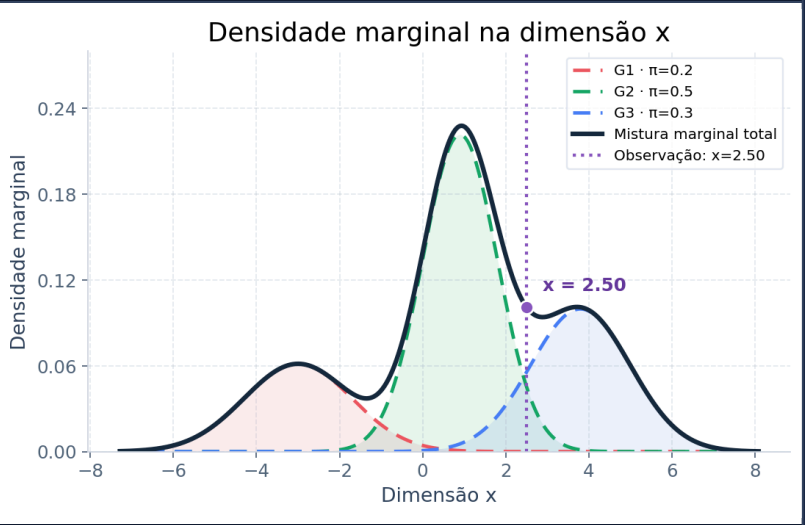
Distribuição marginal em y no modelo 2D.

EXEMPLO 3D

3D — três marginais

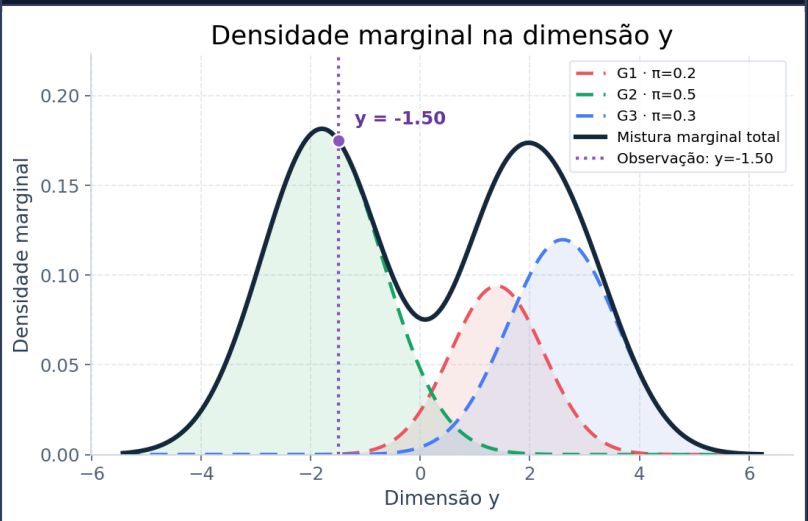
Três imagens: marginais das dimensões x, y e z.

Marginal da dimensão x



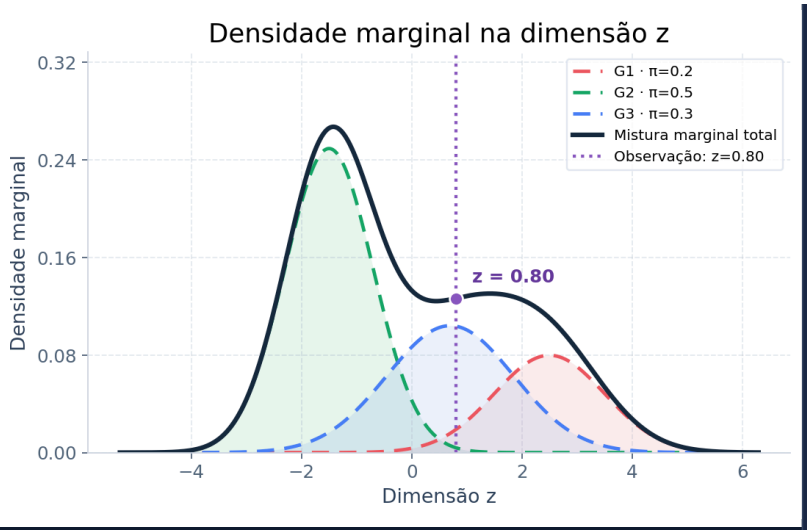
Distribuição marginal em x no modelo 3D.

Marginal da dimensão y



Distribuição marginal em y no modelo 3D.

Marginal da dimensão z



Distribuição marginal em z no modelo 3D.

Este é o primeiro gráfico do grupo de gráficos de GMM. Ele mostra marginais por dimensão e serve como visualização introdutória da geometria unidimensional da mistura.

GRÁFICO 09

Painel de parâmetros dos componentes gaussianos

No lugar dos heatmaps de médias e covariâncias, este painel exibe, ao lado do mapa ou do gráfico principal, as informações matemáticas mais úteis de cada componente: **peso π_k**, **risco r_k**, **vetor de médias μ_k** e **matriz de variâncias/covariâncias Σ_k**. Como o seu modelo usa **covariance_type = full**, a matriz deve ser mostrada completa, incluindo as covariâncias fora da diagonal.

Por que este painel é mais interessante que os heatmaps?

- Em 1D, 2D e 3D, os valores numéricos ficam legíveis de forma imediata.
- Evita interpretar cores quando a matriz Σ_k é pequena e pode ser lida diretamente.
- Mostra, no mesmo lugar, posição, dispersão, peso na mistura e risco estimado do componente.
- Em `full`, preserva explicitamente as correlações/covariâncias entre dimensões.

Descrição para a próxima IA

Gerar um painel por componente com os seguintes campos:

```
Componente k → { π_k, r_k, status, μ_k, Σ_k }
```

Regra ilustrativa de status neste catálogo: **Fraude** se $r_k \geq 0.50$; caso contrário, **Não fraude**. No projeto real, o risco deve vir do cálculo com responsabilidades e rótulos do treino.

EXEMPLO 1D

1D — painel matemático dos componentes

Uma dimensão apenas, com painel por componente exibindo peso, risco, vetor de médias e matriz de variâncias/covariâncias completa.

G1 Não fraude

Peso	Risco
$\pi_k = 0.20$	$r_k = 0.08$

Vetor de médias μ_k

[-3.00]

Matriz Var/Cov Σ_k (FULL)

[[1.96]]

G2

Fraude

Peso
$\pi_k = 0.50$

Risco
$r_k = 0.62$

Vetor de médias μ_k

[0.90]

Matriz Var/Cov Σ_k (FULL)

[[0.90]]

G3

Não fraude

Peso
$\pi_k = 0.30$

Risco
$r_k = 0.31$

Vetor de médias μ_k

[4.70]

Matriz Var/Cov Σ_k (FULL)

[[1.44]]

EXEMPLO 2D

2D — painel matemático dos componentes

Duas dimensãoões, com painel por componente exibindo peso, risco, vetor de médias e matriz de variâncias/covariâncias completa.

G1

Não fraude

Peso
$\pi_k = 0.25$

Risco
$r_k = 0.12$

Vetor de médias μ_k

```
[-3.00, 1.30]
```

Matriz Var/Cov Σ_k (FULL)

```
[[1.82, 0.38], [0.38, 0.94]]
```

G2

Fraude

Peso
$\pi_k = 0.45$

Risco
$r_k = 0.71$

Vetor de médias μ_k

```
[0.80, -1.80]
```

Matriz Var/Cov Σ_k (FULL)

```
[[0.92, -0.27], [-0.27, 1.10]]
```

G3

Não fraude

Peso
$\pi_k = 0.30$

Risco
$r_k = 0.44$

Vetor de médias μ_k

```
[3.90, 2.80]
```

Matriz Var/Cov Σ_k (FULL)

```
[[1.44, 0.35], [0.35, 1.20]]
```

EXEMPLO 3D

3D — painel matemático dos componentes

Três dimensãoões, com painel por componente exibindo peso, risco, vetor de médias e matriz de variâncias/covariâncias completa.

G1

Não fraude

Peso
$\pi_k = 0.20$

Risco
$r_k = 0.15$

Vetor de médias μ_k

```
[-3.00, 1.40, 2.50]
```

Matriz Var/Cov Σ_k (FULL)

```
[[1.70, 0.25, 0.18], [0.25, 0.86, 0.12], [0.18, 0.12, 1.05]]
```

G2

Fraude

Peso
$\pi_k = 0.50$

Risco
$r_k = 0.78$

Vetor de médias μ_k

```
[0.90, -1.80, -1.50]
```

Matriz Var/Cov Σ_k (FULL)

```
[[0.88, -0.22, 0.15], [-0.22, 1.21, -0.29],
[0.15, -0.29, 0.76]]
```

G3

Não fraude

Peso
$\pi_k = 0.30$

Risco
$r_k = 0.41$

Vetor de médias μ_k

```
[3.80, 2.60, 0.70]
```

Matriz Var/Cov Σ_k (FULL)

```
[[1.36, 0.31, -0.12], [0.31, 1.05, 0.20],
[-0.12, 0.20, 1.28]]
```

Comandos para a próxima IA

1. Ler `gmm.weights_`, `gmm.means_` e `gmm.covariances_`.
2. Se `covariance_type == 'full'`, exibir Σ_k completa; não resumir a um vetor diagonal.
3. Calcular ou receber o risco do componente `r_k` e mostrar também o rótulo resumo “Fraude” ou “Não fraude”.
4. Para 1D, mostrar μ com 1 posição e Σ 1×1; para 2D, μ com 2 posições e Σ 2×2; para 3D, μ com 3 posições e Σ 3×3.
5. Manter a mesma cor da gaussiana no gráfico espacial, na legenda e no painel matemático.
6. Adicionar este painel ao lado do mapa/gráfico principal correspondente.

Valores do catálogo são **simulados apenas para ilustração**. Estrutura pronta para ser substituída pelos parâmetros reais do seu GMM.

GRÁFICO 04

Regiões de dominância dos componentes gaussianos

Este gráfico mostra **qual gaussiana domina cada posição do espaço**, isto é, qual componente possui a maior responsabilidade em cada ponto. Ele representa a estrutura interna da mistura e as fronteiras entre componentes.

O que ele é

A regra do gráfico é:

$$k^*(x) = \operatorname{argmax}_k \gamma_k(x)$$

Ou seja, para cada ponto do espaço, identificamos o componente com a maior responsabilidade e colorimos a região com a cor desse componente.

Importante: este gráfico **não** é a fronteira de fraude versus não fraude. Ele mostra apenas a **dominância entre componentes gaussianos**. O risco de fraude continua sendo calculado separadamente pela combinação das responsabilidades com os riscos dos componentes.

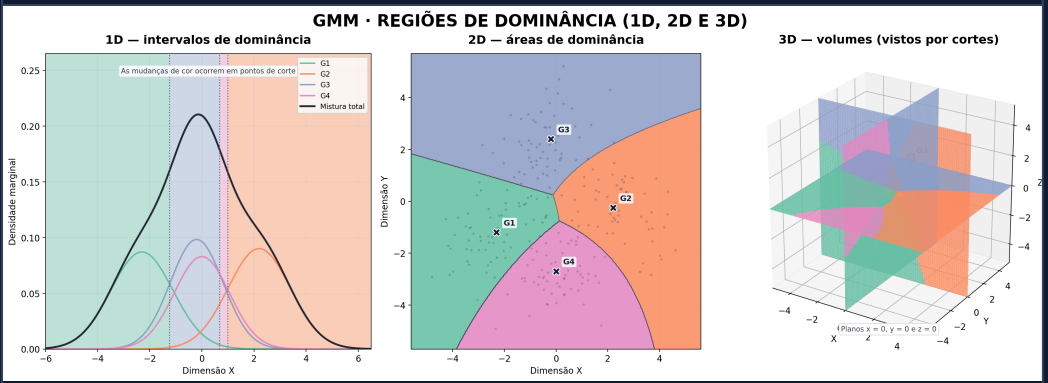
$$P(\text{fraude} \mid x) = \Sigma_{k=1\ldots K}\, \gamma_k(x) \cdot r_k$$

Como fica em cada dimensionalidade

Dimensão	Representação	Fronteira
1D	intervalos coloridos ao longo de x	pontos de transição
2D	áreas coloridas no plano x-y	linhas/curvas
3D	volumes coloridos no espaço x-y-z	superfícies

Em 3D, o mais indicado é usar **cortes (slices)** do volume, porque uma visualização sólida opaca costuma esconder as regiões internas.

Comparativo visual — 1D, 2D e 3D



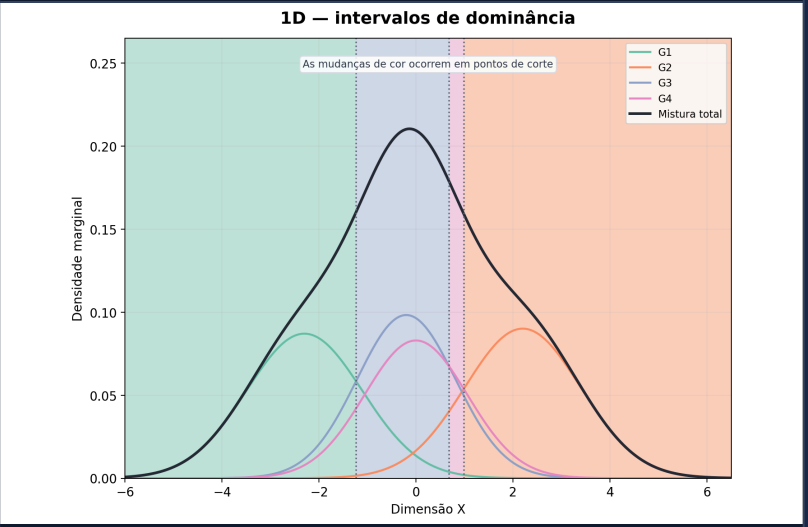
Exemplo ilustrativo com quatro componentes gaussianos. As cores indicam a gaussiana dominante em cada região do espaço.

EXEMPLO 1D

1D — intervalos de dominância

Em uma dimensão, a dominância aparece como segmentos coloridos ao longo do eixo x. As mudanças de cor marcam os pontos em que outra gaussiana passa a ter maior responsabilidade.

Regiões de dominância em 1D



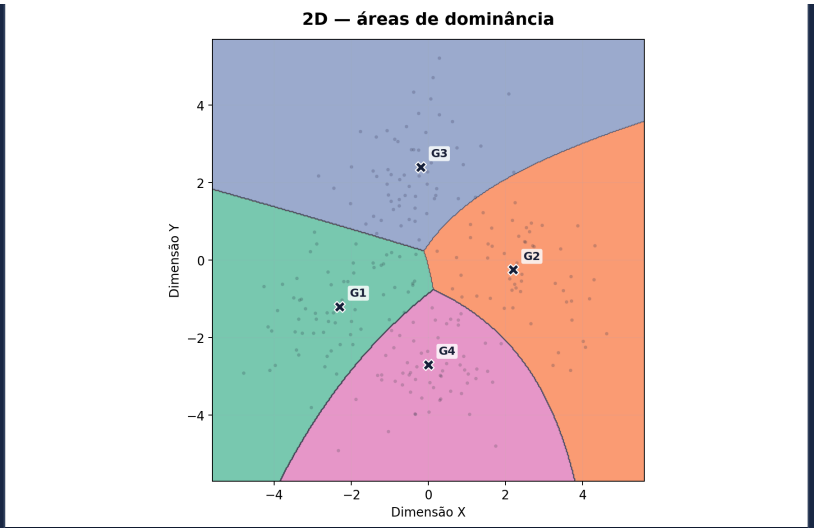
Cada faixa colorida representa o componente dominante naquele intervalo do eixo x.

EXEMPLO 2D

2D — áreas de dominância

No plano x-y, a dominância aparece como áreas coloridas. Com `covariance_type = full`, as fronteiras podem ser curvas, pois dependem das médias, covariâncias e pesos dos componentes.

Regiões de dominância em 2D



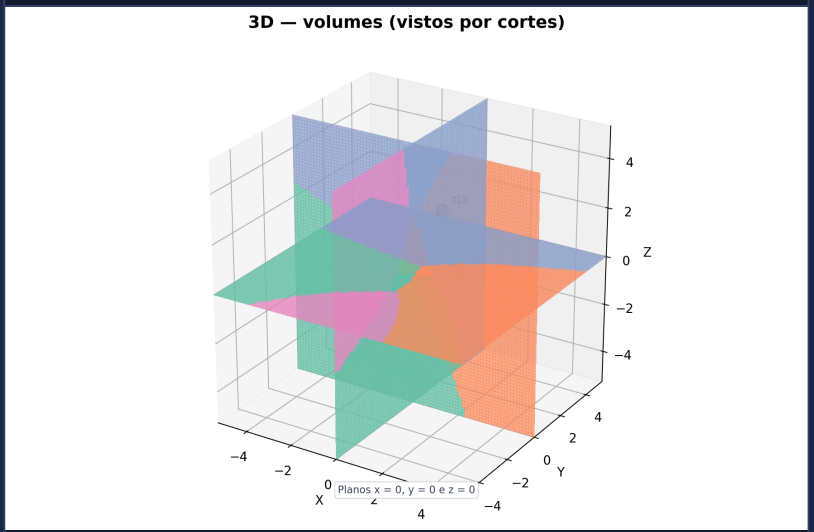
As linhas/fronteiras separam áreas nas quais cada gaussiana possui a maior responsabilidade.

EXEMPLO 3D

3D — volumes de dominância

No espaço x-y-z, a dominância forma volumes. Para visualizar o interior, o ideal é mostrar cortes planares do volume, revelando as regiões dominantes sem esconder as partes internas.

Regiões de dominância em 3D (cortes)



Exemplo em 3D representado por slices/cortes para

tornar os volumes internos visíveis.

Instruções para a IA — como gerar este gráfico

1. Ajustar ou receber um GMM com K componentes, além de `weights_`, `means_` e `covariances_`.
2. Definir o espaço de visualização: reta em 1D, malha cartesiana em 2D ou volume/cortes em 3D.
3. Para cada ponto da malha, calcular as responsabilidades `γ_k(x)` usando o GMM.
4. Aplicar `argmax_k γ_k(x)` para identificar o componente dominante no ponto.
5. Colorir a região conforme o componente dominante, mantendo a mesma cor da gaussiana em todo o catálogo.
6. Sobrepor, quando desejado, os centros das gaussianas (μ_k) e pontos observados.
7. Se houver risco por componente `r_k`, exibir esse valor nos rótulos ou ao lado do gráfico, mas deixar explícito que ele é um metadado adicional e que o mapa continua sendo de dominância, não de fraude.
8. Para 3D, preferir **cortes** ou slices em vez de volumes totalmente opacos.

Comando resumido para a próxima IA

```
Gerar o gráfico “Regiões de dominância dos
componentes gaussianos”.

Regra matemática: k*(x) = argmax_k γ_k(x).

Mostrar:
- 1D: intervalos coloridos ao longo de x.
- 2D: áreas coloridas no plano x-y.
- 3D: volumes de dominância usando cortes/slices.
```

```
Incluir:
- mesmas cores dos componentes em todo o catálogo;
- centros das gaussianas;
- opcionalmente, pontos observados;
- risco por componente apenas como rótulo auxiliar.

Importante: deixar claro que o gráfico mostra
dominância entre componentes, e não a fronteira
fraude vs. não fraude.
```

Leitura correta do gráfico

- Uma região dominada por G3 não significa risco de fraude igual ao risco de G3 em todos os pontos.
- Outros componentes ainda podem contribuir para a observação, mesmo fora da sua região dominante.
- O mapa de dominância explica a **estrutura da mistura**; o mapa de risco explica a **classificação**.

Os exemplos deste bloco são simulados e servem para documentar a forma de visualização do gráfico no catálogo. Substitua pelos parâmetros reais do seu GMM quando integrar ao projeto.

GRÁFICO 07

Sensibilidade da fronteira ao limiar de classificação

Compara a fronteira do mesmo classificador nos cortes τ = 0,50 e τ* (ótimo por MCC). A região hachurada indica onde a classificação realmente mudou entre os dois limiares.

O que o gráfico mostra

A mistura gaussiana FULL produz um score de risco conjunto, mantendo todos os componentes e seus parâmetros fixos entre os painéis.

$$s(x) = \Sigma_k \; y_k(x) \cdot r_k$$

Os contornos pretos são os conjuntos de nível $s(x)=\tau$; não delimitam gaussianas. Reduzir o limiar expande a região de fraude, embora a curva possa mudar radicalmente de forma, surgir ou desaparecer de um corte.

Regra de comparação e legenda

Esquerda: corte 0,50. **Direita:** corte ótimo MCC. Cada painel mostra seu MCC no mesmo conjunto de avaliação.

Se $\tau^* < 0{,}50$, a região de fraude no ótimo **contém** toda a região de fraude do corte fixo. Caso $\tau^* > 0{,}50$, ocorre o inverso.

A superfície de risco e a escala de cores não mudam: **somente o limiar e a classe mudam**.

EXEMPLO 1D • DADOS SIMULADOS

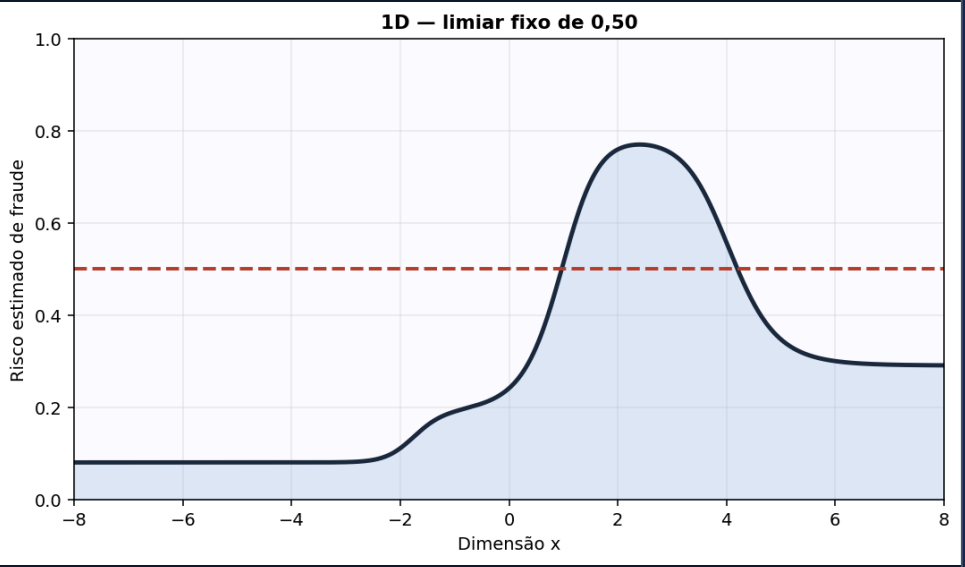
1D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



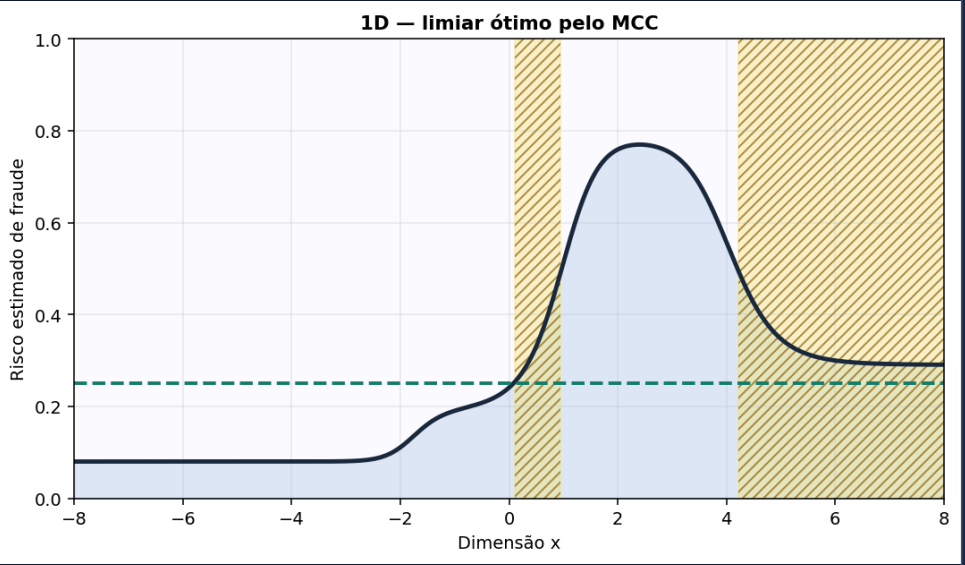
Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita.

Limiar (τ)	0.500
MCC na avaliação simulada	0.287

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.251



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*.

Limiar (τ)	0.251
MCC na avaliação simulada	0.344

Leitura da comparação: **Score < 0.251: legítima nos dois**

0.251 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

EXEMPLO 2D • DADOS SIMULADOS

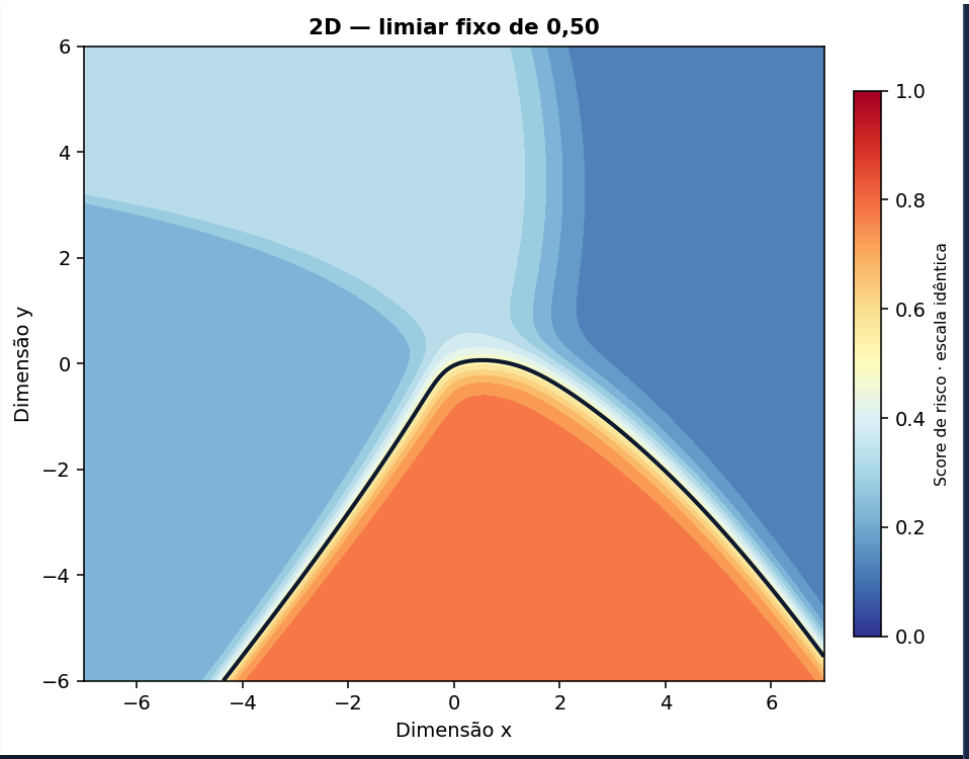
2D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita.

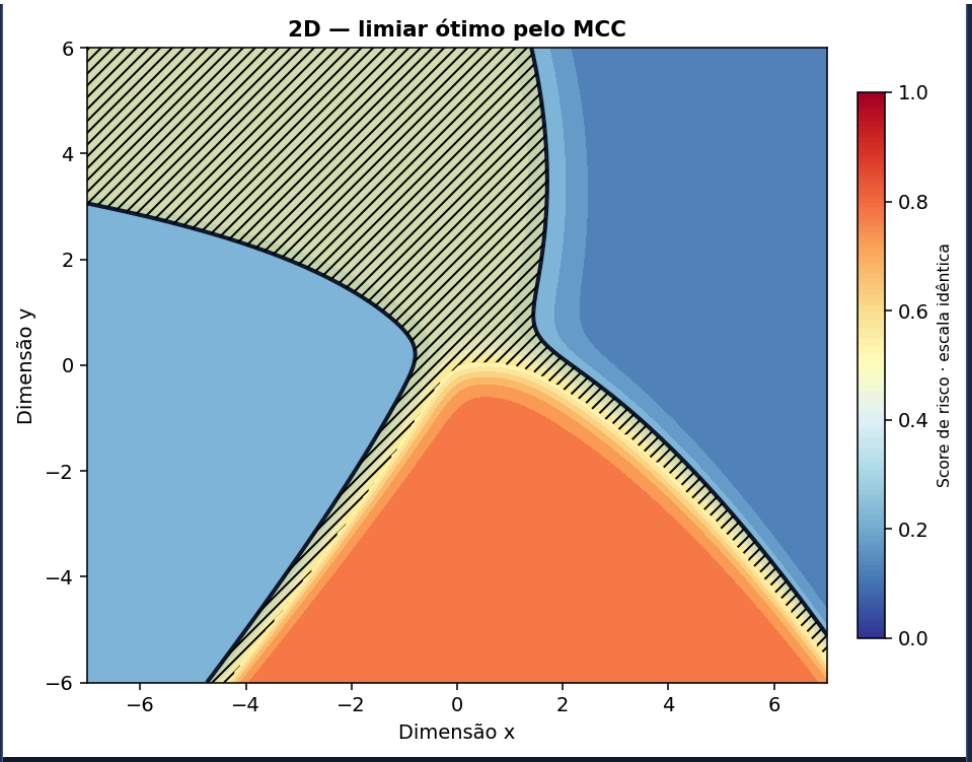
Limiar (τ)	**0.500**

MCC na avaliação simulada	**0.224**

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.255



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*.

Limiar (τ)	**0.255**
MCC na avaliação simulada	**0.295**

Leitura da comparação:

Score < 0.255: legítima nos dois

0.255 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

EXEMPLO 3D • DADOS SIMULADOS

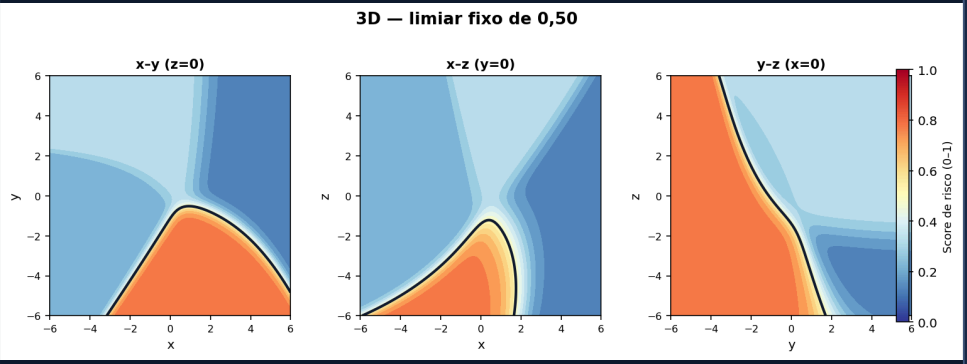
3D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita.

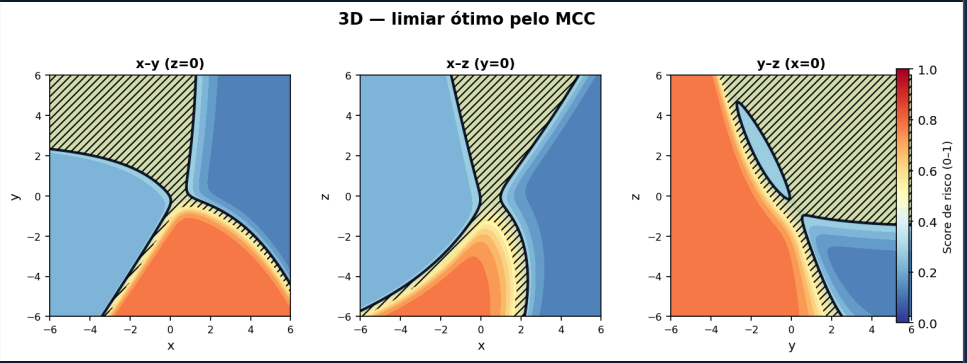
Limiar (τ)	**0.500**

MCC na avaliação simulada	**0.217**

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.290



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*.

Limiar (τ)	**0.290**
MCC na avaliação simulada	**0.255**

Leitura da comparação: **Score < 0.290: legítima nos dois**

0.290 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

Instruções obrigatórias para a outra IA — Gráfico 07

1. Gerar exatamente **dois gráficos por dimensionalidade**: primeiro τ=0,50 e depois τ=τ* com MCC ótimo calculado sobre as predições **OOF** (ou avaliação independente claramente identificada).
2. Obter as responsabilidades do GMM com `covariance_type='full'` e calcular `s(x) = Σ_k y_k(x)·r_k`. Os `r_k` são estimados com os rótulos do treino, não com o fold de validação.
3. Manter exatamente **a mesma malha, os mesmos limites, as mesmas cores, as mesmas observações, os mesmos cortes de 3D e o mesmo score** nos dois painéis.
4. Calcular as máscaras `pred_fixo = (s >= 0.50)` e `pred_otimo = (s >= tau_star)`; criar `mudou = pred_fixo XOR pred_otimo`.
5. Destacar `mudou` no painel ótimo com **hachura amarela sem apagar a superfície de risco**. Descrever a direção da troca de classe conforme a ordem dos limiares.
6. Manter a linha preta como contorno `s(x)=τ` correspondente em cada gráfico. Em um corte sem cruzamento com τ, **não**

fabricar contorno; explicar que nesse plano a fronteira não aparece.

7. 1D: mesma curva de risco com regiões x hachuradas onde houve mudança; 2D: mesmo campo conjunto X–Y com região hachurada; 3D: dois conjuntos de cortes X–Y, X–Z e Y–Z do mesmo campo conjunto, com hachura da mudança em cada corte. Não transformar em marginais.
8. Exibir no rodapé de cada gráfico seu próprio valor `τ` e `MCC(τ)`, calculado sempre sobre **as mesmas predições/observações de avaliação**, jamais sobre a malha.
9. **Verificação matemática obrigatória:** se `tau_star < 0.50`, todo ponto com `pred_fixo=True` também precisa ter `pred_otimo=True`; se `tau_star > 0.50`, `pred_otimo` deve ser subconjunto de `pred_fixo`. Se não cumprir, interromper a geração e sinalizar divergência de scores, malha ou comparação.
10. Quando τ* = 0,50, apresentar os dois gráficos iguais e informar **nenhuma mudança de classe**. Para modelos com mais de 3 dimensões, declarar os valores fixados para cortes.

Teste automatizado sugerido (Python)

```
score = np.asarray(score_malha, dtype=float)
fixo = score >= 0.50
otimo = score >= tau_star
mudou = np.logical_xor(fixo, otimo)
assert np.array_equal(mudou, fixo != otimo)
if tau_star < 0.50:
    assert np.all(np.logical_or(~fixo, otimo)),
"Fraude no fixo virou legítima: verificar
implementação"
elif tau_star > 0.50:
    assert np.all(np.logical_or(~otimo, fixo)),
"Fraude no ótimo fora da região fixa: verificar
implementação"
else:
    assert not mudou.any()
```

Os dados, os scores e as métricas deste HTML são **simulados**, usados apenas como referência de implementação. Em produção, o MCC deve ser calculado com os resultados OOF reais do pipeline, e a mudança de classe deve usar a mesma função de risco para ambos os limiares.

GRÁFICO 08

Mapa de risco, fronteira e geometria dos componentes gaussianos (95%)

Além da fronteira, mostra médias, observações amostrais e regiões gaussianas centrais de 95%, com os dois cortes obrigatórios (0,50 versus MCC ótimo) e hachura das regiões que mudaram de classe.

O que o gráfico mostra

A mistura gaussiana FULL produz um score de risco conjunto, mantendo todos os componentes e seus parâmetros fixos entre os painéis.

$$s(x) = \Sigma_k \; \gamma_k(x) \cdot r_k$$

As regiões tracejadas de 95% são regiões de massa gaussiana, não limites de fraude. Para 2D usam χ^2 com 2 graus de liberdade; em 3D, os cortes dos elipsoides usam χ^2 com 3 graus de liberdade e a matriz FULL.

Regra de comparação e legenda

Esquerda: corte 0,50. **Direita:** corte ótimo MCC. Cada painel mostra seu MCC no mesmo conjunto de avaliação.

Se $\tau^* < 0{,}50$, a região de fraude no ótimo **contém** toda a região de fraude do corte fixo. Caso $\tau^* > 0{,}50$, ocorre o inverso.

A superfície de risco e a escala de cores não mudam: **somente o limiar e a classe mudam**.

EXEMPLO 1D • DADOS SIMULADOS

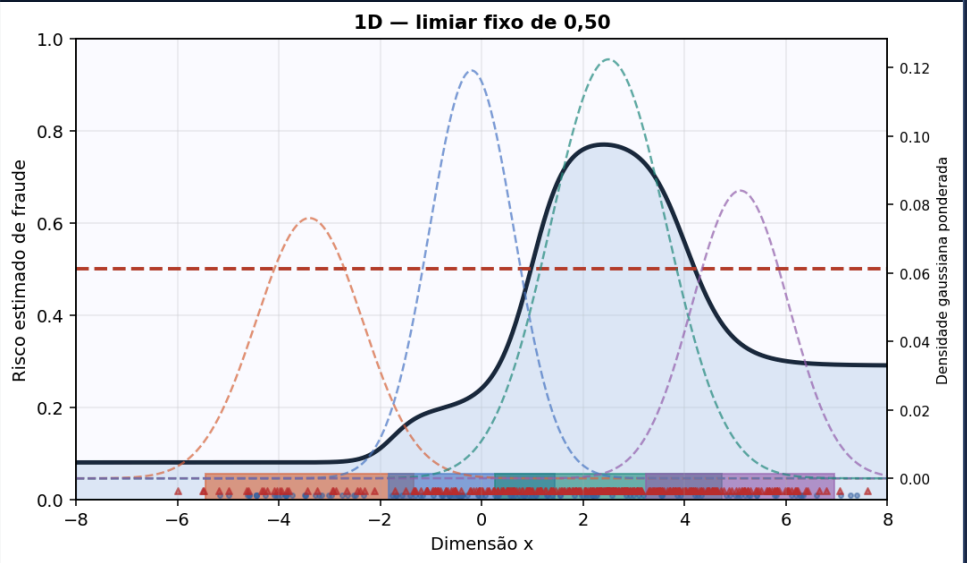
1D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita. As linhas tracejadas são

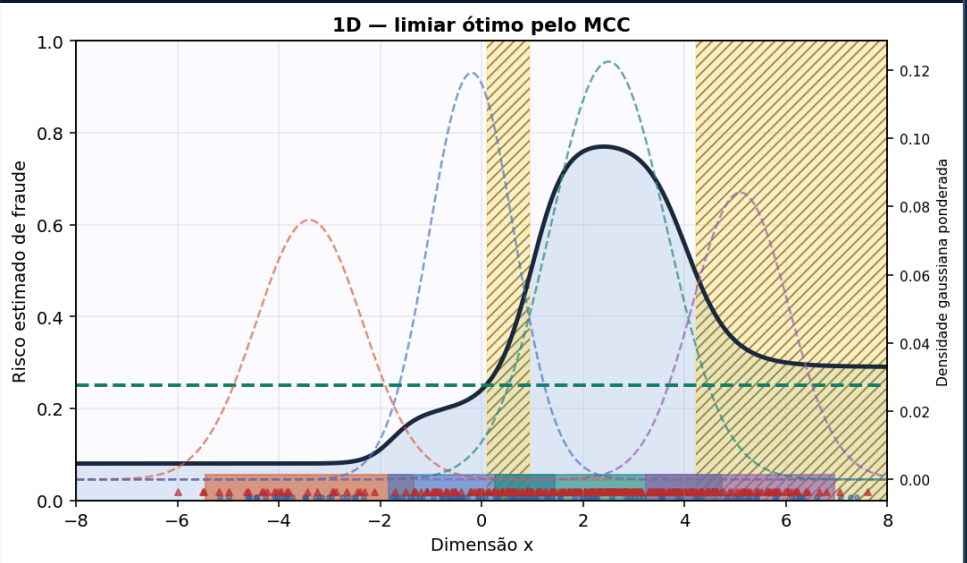
regiões gaussianas de 95%.

Limiar (τ)	**0.500**
MCC na avaliação simulada	**0.287**

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.251



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*. As linhas tracejadas são regiões gaussianas de 95%.

Limiar (τ)	**0.251**
MCC na avaliação simulada	**0.344**

Leitura da comparação: **Score < 0.251: legítima nos dois**

0.251 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

EXEMPLO 2D • DADOS SIMULADOS

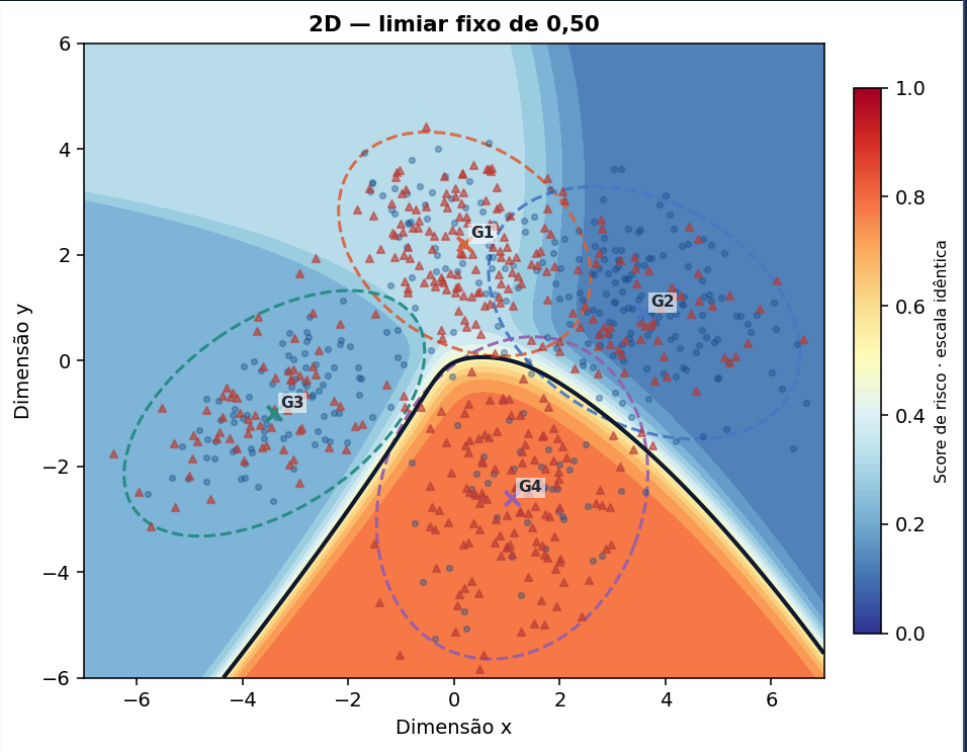
2D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



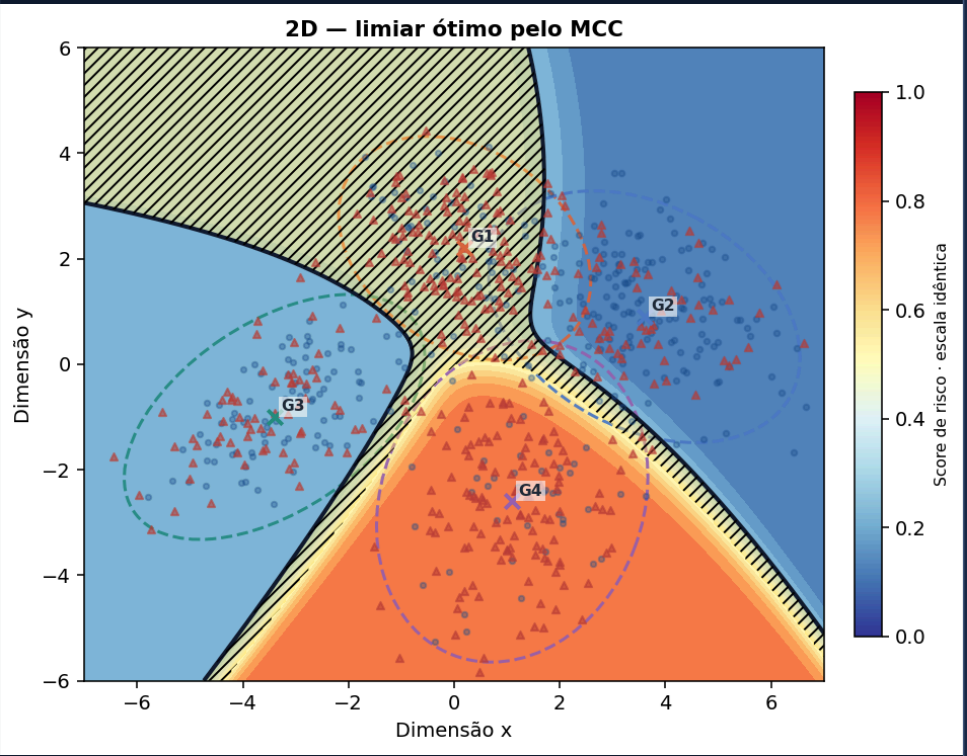
Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita. As linhas tracejadas são regiões gaussianas de 95%.

Limiar (τ)	**0.500**
MCC na avaliação simulada	**0.224**

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.255



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*. As linhas tracejadas são regiões gaussianas de 95%.

Limiar (τ)	**0.255**
MCC na avaliação simulada	**0.295**

Leitura da comparação:

Score < 0.255: legítima nos dois

0.255 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

EXEMPLO 3D • DADOS SIMULADOS

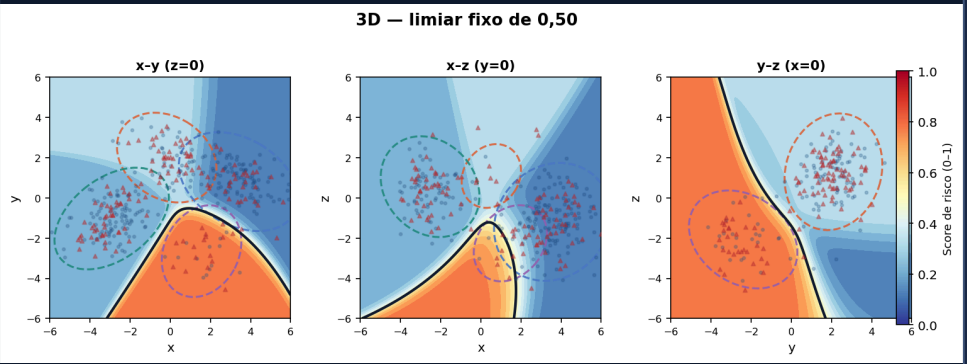
3D — duas visualizações conjuntas, com destaque da mudança

Os dois painéis usam o **mesmo GMM, o mesmo campo de risco** e a mesma escala. Na imagem da direita, a hachura amarela destaca os pontos cuja classe mudou: **Legítima em 0,50 → fraude no ótimo**.

LIMIAR FIXO

Corte fixo de 50%

τ = 0.500



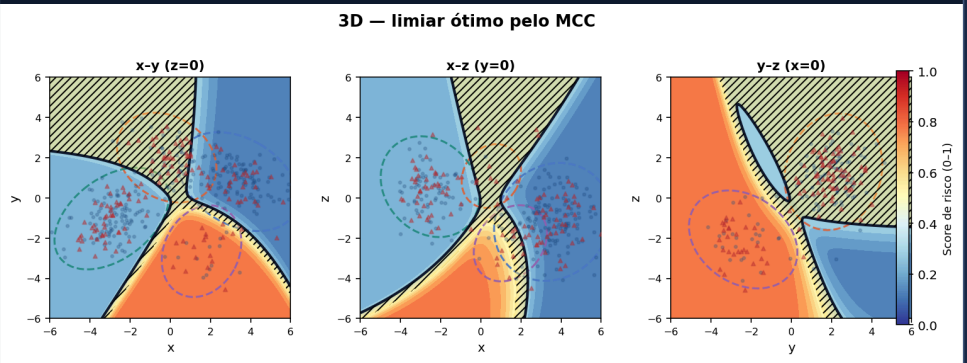
Linha preta: fronteira s(x)=0,50. O fundo representa o mesmo score contínuo da imagem da direita. As linhas tracejadas são regiões gaussianas de 95%.

Limiar (τ)	**0.500**
MCC na avaliação simulada	**0.217**

LIMIAR ÓTIMO PELO MCC

Corte ótimo por MCC

τ = 0.290



Hachura amarela: pontos que mudaram de classe ao comparar os cortes; a curva preta delimita s(x)=τ*. As linhas tracejadas são regiões gaussianas de 95%.

Limiar (τ)	**0.290**
MCC na avaliação simulada	**0.255**

Leitura da comparação: **Score < 0.290: legítima nos dois**

0.290 ≤ score < 0.500: mudou (legítima → fraude)

Score ≥ 0.500: fraude nos dois

A hachura destaca *regiões do espaço*, não a proporção de observações. Em 3D, os painéis exibem cortes da mesma função tridimensional nos mesmos planos, não densidades marginais.

Instruções obrigatórias para a outra IA — Gráfico 08

1. Gerar exatamente **dois gráficos por dimensionalidade**: primeiro τ=0,50 e depois τ=τ* com MCC ótimo calculado sobre as predições **OOF** (ou avaliação independente claramente identificada).
2. Obter as responsabilidades do GMM com `covariance_type='full'` e calcular `s(x) = Σ_k y_k(x)·r_k`. Os `r_k` são estimados com os rótulos do treino, não com o fold de validação.
3. Manter exatamente **a mesma malha, os mesmos limites, as mesmas cores, as mesmas observações, os mesmos cortes de 3D e o mesmo score** nos dois painéis.
4. Calcular as máscaras `pred_fixo = (s >= 0.50)` e `pred_otimo = (s >= tau_star)`; criar `mudou = pred_fixo XOR pred_otimo`.
5. Destacar `mudou` no painel ótimo com **hachura amarela sem apagar a superfície de risco**. Descrever a direção da troca de classe conforme a ordem dos limiares.

6. Manter a linha preta como contorno `s(x)=τ` correspondente em cada gráfico. Em um corte sem cruzamento com τ, **não fabricar contorno**; explicar que nesse plano a fronteira não aparece.
7. 1D: mesma curva de risco com regiões x hachuradas onde houve mudança; 2D: mesmo campo conjunto X–Y com região hachurada; 3D: dois conjuntos de cortes X–Y, X–Z e Y–Z do mesmo campo conjunto, com hachura da mudança em cada corte. Não transformar em marginais.
8. Manter as regiões gaussianas de **95%**: em 1D intervalos; em 2D elipses com `chi2.ppf(0.95,df=2)`; em 3D elipsoides com `chi2.ppf(0.95,df=3)`, cuja interseção com cada plano é obtida da matriz FULL. Mostrar as mesmas gaussianas em ambos os painéis.
9. Exibir no rodapé de cada gráfico seu próprio valor τ e `MCC(τ)`, calculado sempre sobre **as mesmas predições/observações de avaliação**, jamais sobre a malha.
10. **Verificação matemática obrigatória:** se `tau_star < 0.50`, todo ponto com `pred_fixo=True` também precisa ter `pred_otimo=True`; se `tau_star > 0.50`, `pred_otimo` deve ser subconjunto de `pred_fixo`. Se não cumprir, interromper a geração e sinalizar divergência de scores, malha ou comparação.
11. Quando τ* = 0,50, apresentar os dois gráficos iguais e informar **nenhuma mudança de classe**. Para modelos com mais de 3 dimensões, declarar os valores fixados para cortes.

Teste automatizado sugerido (Python)

```
score = np.asarray(score_malha, dtype=float)
fixo = score >= 0.50
otimo = score >= tau_star
mudou = np.logical_xor(fixo, otimo)
assert np.array_equal(mudou, fixo != otimo)
if tau_star < 0.50:
    assert np.all(np.logical_or(~fixo, otimo)),
"Fraude no fixo virou legítima: verificar
```

```
implementação"
elif tau_star > 0.50:
    assert np.all(np.logical_or(~otimo, fixo)),
"Fraude no ótimo fora da região fixa: verificar
implementação"
else:
    assert not mudou.any()
```

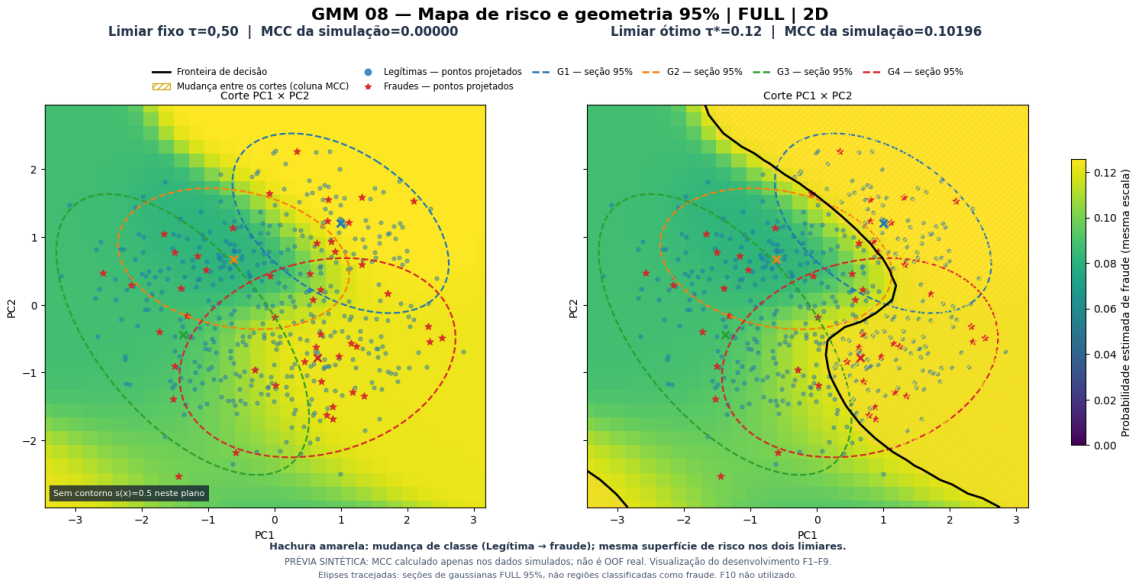
> Os dados, os scores e as métricas deste HTML são **simulados**, usados apenas como referência de implementação. Em produção, o MCC deve ser calculado com os resultados OOF reais do pipeline, e a mudança de classe deve usar a mesma função de risco para ambos os limiares.

GRÁFICO 08 / P05

Comparativo de risco — 2D

Versão integrada no projeto e aprovada nos testes automatizados (434/434).

Painel esquerdo: limiar τ = 0,50. Painel direito: limiar τ* obtido por MCC OOF. Ambos usam o mesmo campo de risco do GMM FULL, a mesma escala e as elipses gaussianas de 95%.



A hachura identifica regiões onde a classificação muda quando o limiar é substituído; MCCs exibidos pertencem ao exemplo simulado da figura. Os outputs reais serão gerados durante a execução experimental.

GRÁFICO 08 / P05

Comparativo de risco — 3D

Seis painéis: três cortes da representação conjunta 3D nos dois limiares.

Linhas: PC1×PC2, PC1×PC3, PC2×PC3. Colunas: τ = 0,50 e τ* MCC OOF. Todos os cortes são projeções da mesma geometria GMM FULL; nenhuma gaussiana é reajustada por painel.

