GRÁFICOS DE PCA

Catálogo visual e técnico — Análise de Componentes Principais

Catálogo independente

Base inicial

Exemplos e gráficos serão acrescentados progressivamente

FUNDAMENTAÇÃO

O que é PCA?

A **Análise de Componentes Principais (PCA)** é uma transformação linear não supervisionada que constrói novas direções ortogonais para representar a variabilidade dos dados. Os componentes são ordenados pela variância capturada, permitindo selecionar uma representação de menor dimensionalidade.

$$Z = (X - \mu)_{\text{centralizado}} \cdot W_d$$

Representação conceitual: **X** são os dados de entrada; **μ**, as médias usadas para centralização; $\mathbf{W_d}$, as direções principais selecionadas; e **Z**, os escores/projeções em d componentes. A padronização, quando utilizada, ocorre antes do ajuste do PCA e deve respeitar os folds.

01

Pré-processamento

Preparar e, quando apropriado, padronizar os atributos.

02

Ajuste do PCA

Determinar as direções principais utilizando apenas o treino.

03

04

Projeção

Obter os escores PC1, PC2, PC3...

Diagnóstico visual

Interpretar variância explicada, projeções e estabilidade.

ESCOPO DO CATÁLOGO

PCA aplicado ao projeto de classificação com GMM

O que queremos visualizar

A quantidade de informação retida por componente, a estrutura das observações no novo espaço e o efeito da redução dimensional antes do ajuste do GMM.

Os gráficos serão incluídos um de cada vez, com exemplos matematicamente simulados e explicações para reprodução pela outra IA.

Cuidados metodológicos

- PCA não utiliza o alvo; fraudes e legítimas podem aparecer coloridas apenas para interpretação posterior.
- Pré-processamento e PCA devem ser ajustados exclusivamente nos dados de treino de cada fold, sem vazamento.
- Variância explicada elevada não garante separação de fraudes ou melhor Average Precision.
- Uma projeção 2D não representa exatamente um classificador treinado com mais de duas componentes.

ESPECIFICAÇÃO PARA A PRÓXIMA IA

Regra de construção dos próximos gráficos

Para cada gráfico

1. Apresentar nome, objetivo e leitura matemática correta.
2. Adicionar gráficos simulados reais, gerados numericamente, e incorporados ao HTML.
3. Apresentar versões 1D, 2D e 3D apenas quando fizer sentido para aquele diagnóstico.
4. Indicar claramente o que é treino, validação, OOF ou teste, quando aplicável.

Dados e comandos de implementação

- Documentar os atributos `components_`, `mean_`, `explained_variance_` e `explained_variance_ratio_`, quando pertinentes.
- Explicitar eixos PC1, PC2, PC3 e percentuais de variância por componente.
- Adicionar instruções reproduzíveis usando PCA já ajustado, nunca valores inventados como resultados do TCC.

Estado atual: catálogo de PCA já iniciado com dois gráficos: **11 — Variância explicada / Scree plot** e **12 — Projeção PCA**. Os exemplos são simulados e servem para documentar como a outra IA deve gerar cada visualização no projeto real.

GRÁFICO 11

Variância explicada / Scree plot

Este gráfico avalia quanta variância cada componente principal preserva e como cresce a variância acumulada. Ele ajuda a verificar se **1, 2 ou 3 componentes** são suficientes para representar a maior parte da estrutura dos dados.

O que ele representa

Cada barra mostra a **variância explicada individual** por um componente principal. A linha mostra a **variância explicada acumulada**.

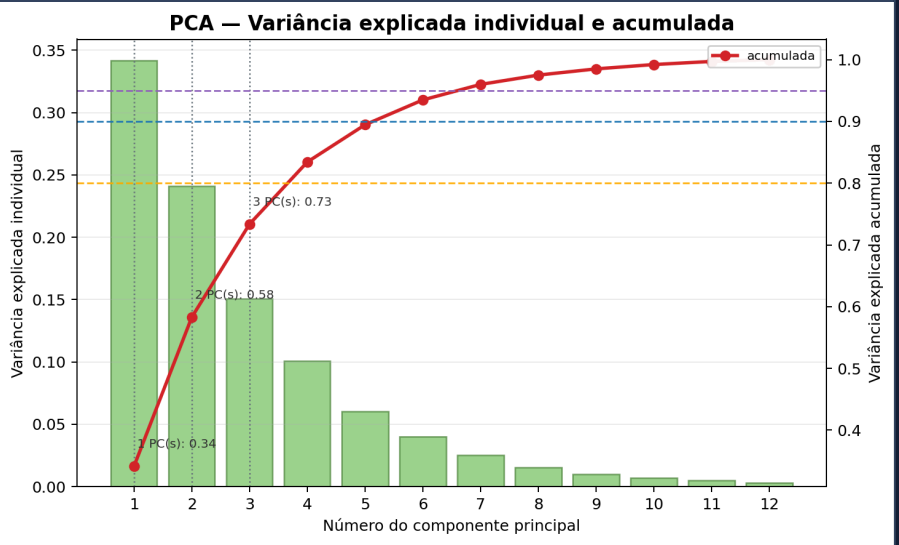
$$ext{Acumulada em }d = \sum_{j=1}^{d} ext{explained_variance_ratio}_j$$

Ele é o gráfico ideal para decidir quantos PCs manter antes de projetar os dados ou treinar o GMM no espaço reduzido.

Leitura correta

- PC1 sozinho pode ser suficiente apenas se capturar informação relevante bastante alta.
- PC1 + PC2 costuma ser a escolha visual mínima para projeções 2D.
- PC1 + PC2 + PC3 permite projeções 3D, mas ainda pode omitir informação importante.
- Mais variância explicada não significa necessariamente melhor separação entre legítimas e fraudes.

Scree plot — variância individual e acumulada



As barras verdes mostram a variância explicada por componente. A linha vermelha mostra a variância acumulada. As marcações em 1, 2 e 3 componentes ajudam a avaliar se essas quantidades são suficientes para o uso pretendido.

Instruções para a outra IA

1. Ler `explained_variance_ratio_` e `explained_variance_` do PCA já ajustado.
2. Plotar barras da variância explicada individual por componente.
3. Sobrepor a linha de variância acumulada.
4. Marcar explicitamente os acumulados em 1, 2 e 3 componentes.
5. Se houver um corte escolhido no projeto, destacar visualmente esse número de componentes.

GRÁFICO 12

Projeção PCA

Este gráfico mostra a distribuição das observações no espaço reduzido do PCA. A regra deste catálogo é direta: **se o PCA final tiver 1 componente, a projeção deve ser 1D — preferencialmente como histograma de PC1; se tiver 2 componentes, deve ser 2D; se tiver 3 componentes, deve ser 3D.**

1 componente → histograma 1D em PC1

2 componentes → projeção 2D

3 componentes → projeção 3D

O que ele representa

Os pontos projetados são os **scores PCA**. Cada observação passa a ser descrita pelas coordenadas em PC1, PC2 e PC3, dependendo do número de componentes mantidos.

$$Z = X_{prep} \cdot W_d$$

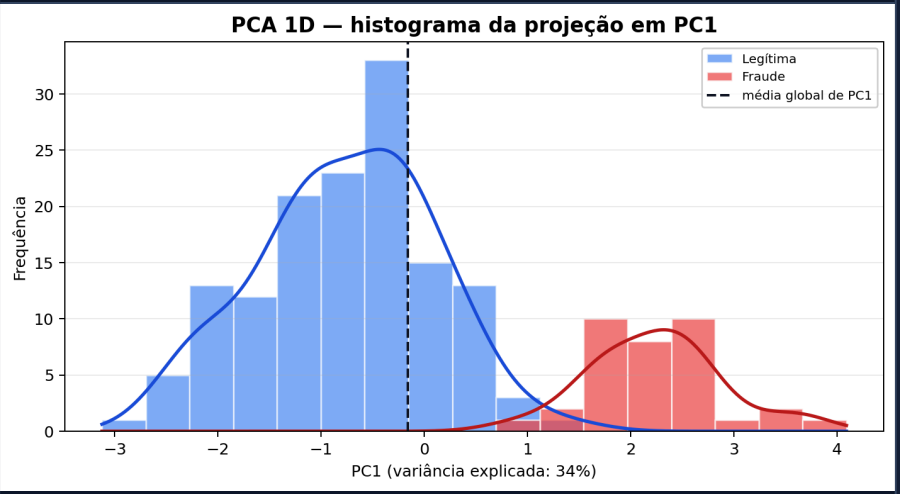
Os rótulos de legítima e fraude podem ser sobrepostos apenas para interpretação visual, pois o PCA é não supervisionado.

Regra metodológica obrigatória

- Não forçar projeção 2D se o PCA selecionado para o modelo final for 1D; nesse caso, preferir histograma em PC1.
- Não forçar projeção 3D se o modelo final estiver usando só 2 componentes.
- A dimensionalidade da imagem deve refletir a dimensionalidade realmente usada pelo PCA selecionado.

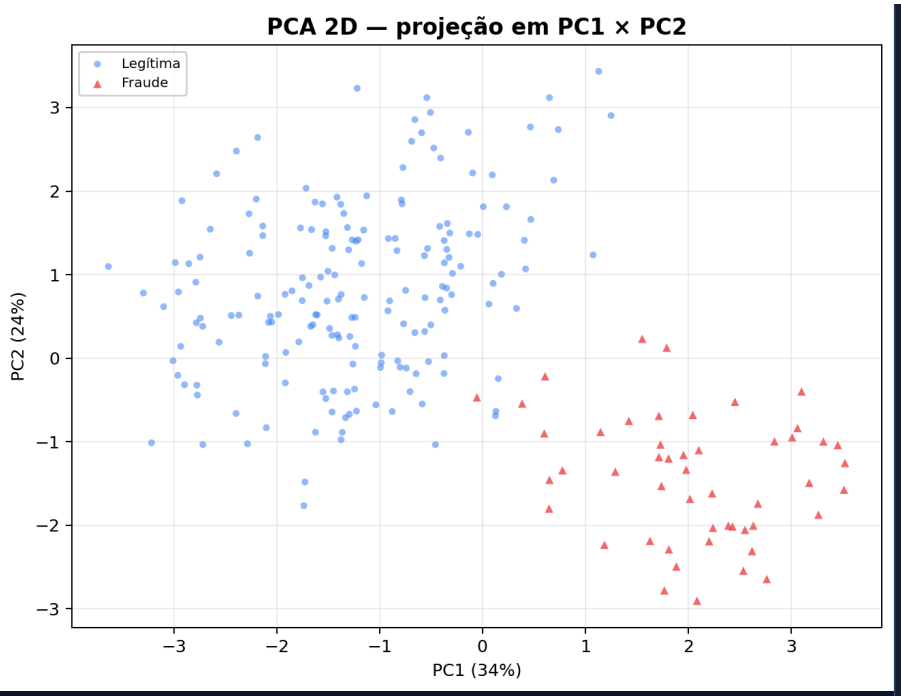
- Informar explicitamente a variância explicada nos eixos PC1, PC2 e PC3.

Exemplo 1D — histograma em PC1



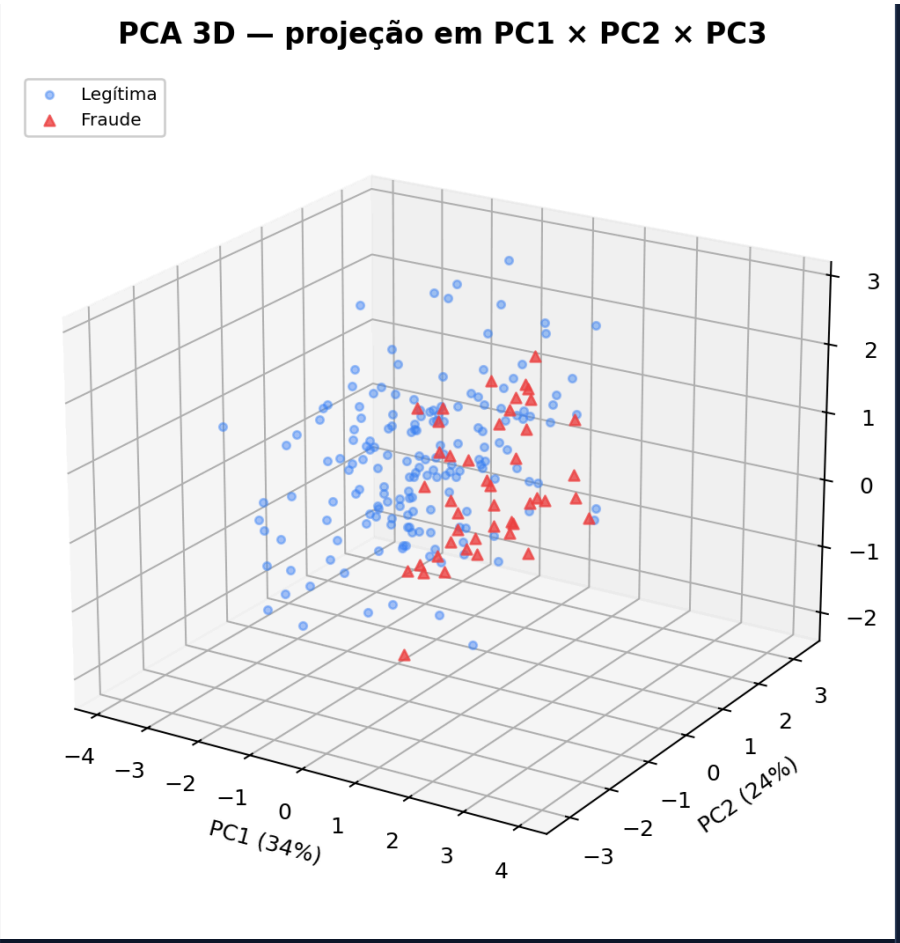
Quando o PCA retido possui **1 componente**, a visualização preferencial é um **histograma de PC1**, opcionalmente com curvas de densidade. Isso mostra melhor a distribuição, a sobreposição entre classes e a concentração das observações ao longo do único eixo disponível.

Exemplo 2D — projeção em PC1 × PC2



Quando o PCA retido possui **2 componentes**, a visualização correta é 2D. Os eixos devem ser **PC1** e **PC2**.

Exemplo 3D — projeção em PC1 × PC2 × PC3



Quando o PCA retido possui **3 componentes**, a visualização correta é 3D. Os eixos devem ser **PC1**, **PC2** e **PC3**.

Instruções para a outra IA

1. Receber ou calcular os **scores PCA** no conjunto desejado (treino, validação, OOF ou teste).
2. Verificar quantos componentes foram mantidos no PCA usado naquele fluxo.
3. Se `n_components = 1`, gerar **histograma 1D** em `PC1`, opcionalmente sobreposto por classe e com curvas de densidade.
4. Se `n_components = 2`, gerar gráfico 2D em `PC1 × PC2`.
5. Se `n_components = 3`, gerar gráfico 3D em `PC1 × PC2 × PC3`.

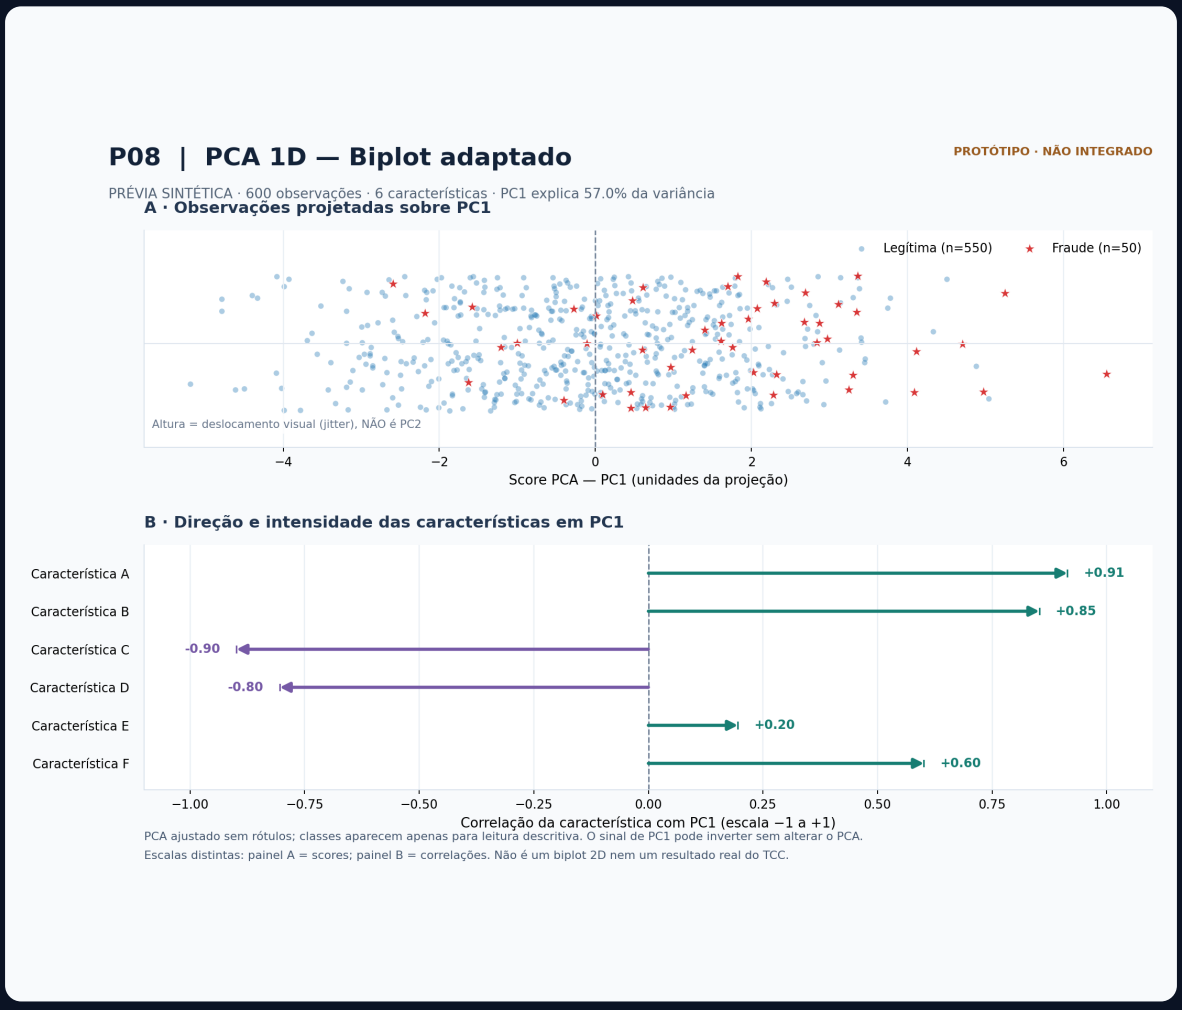
6. Colorir opcionalmente por classe, risco, classe prevista ou gaussiana dominante, mas sem mudar a dimensionalidade da projeção.
7. Indicar no subtítulo e nos eixos a variância explicada correspondente a cada PC exibido.

BIPLOT 1D / IDENTIFICADOR SEM NÚMERO

Biplot PCA — 1 dimensão

Novo gráfico integrado na P08, com nomenclatura dimensional provisória.

A visualização 1D usa o eixo PC1 para posicionar observações; a associação das variáveis originais pré-processadas com PC1 é apresentada sem simular uma segunda componente.



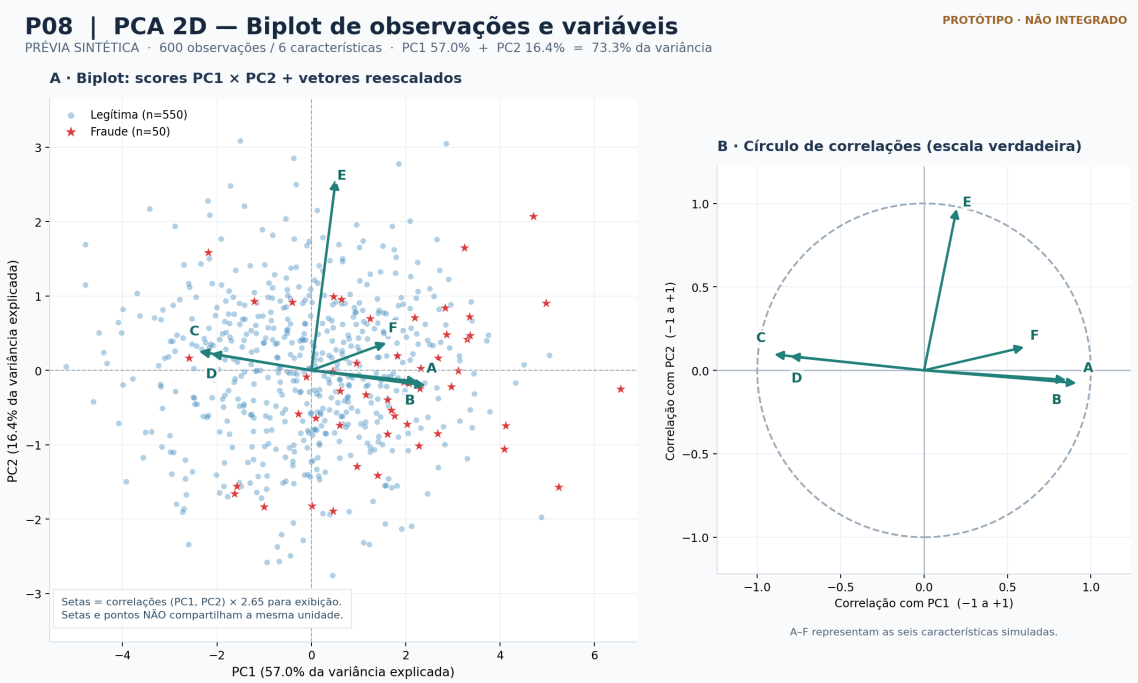
Nome do arquivo da pipeline: PCA_BIPLOT_1D.png. Máximo de setas controlado no YAML (max_setas); apenas a dimensionalidade selecionada é produzida.

BIPLOT 2D / IDENTIFICADOR SEM NÚMERO

Biplot PCA — 2 dimensões

Novo gráfico integrado na P08, com nomenclatura dimensional provisória.

O círculo de correlações e os vetores evidenciam o relacionamento das variáveis pré-processadas com PC1 e PC2. A figura é diagnóstica; os rótulos não entram no ajuste PCA.



Nome do arquivo da pipeline: PCA_BIPLOT_2D.png. Máximo de setas controlado no YAML (max_setas); apenas a dimensionalidade selecionada é produzida.

BIPLOT 3D / IDENTIFICADOR SEM NÚMERO

Biplot PCA — 3 dimensões

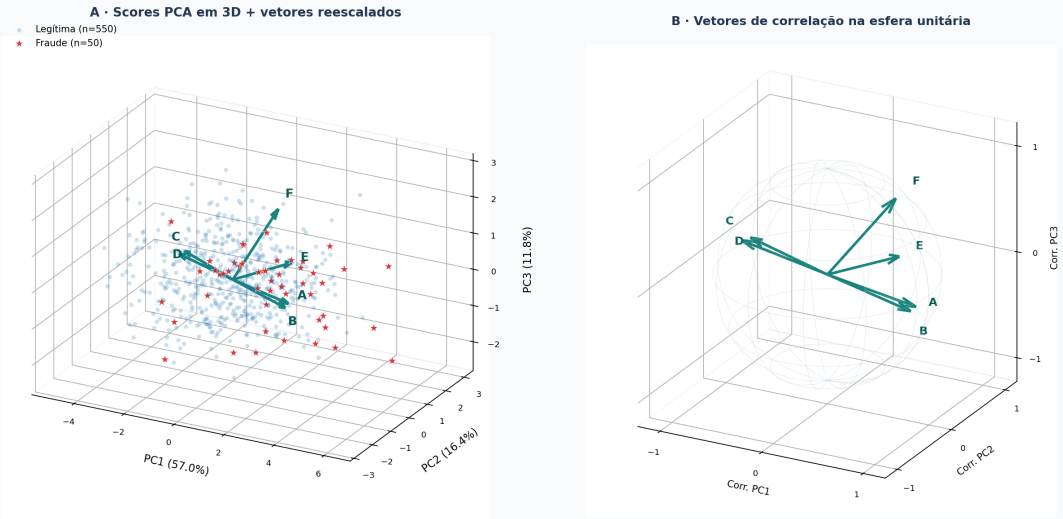
Novo gráfico integrado na P08, com nomenclatura dimensional provisória.

A esfera de correlações e os vetores relacionam as variáveis pré-processadas a PC1, PC2 e PC3. As componentes são obtidas do PCA do desenvolvimento; não há refit para o desenho.

P08 | PCA 3D — Biplot de observações e variáveis

PROTÓTIPO · NÃO INTEGRADO

PRÉVIA SINTÉTICA · 600 observações / 6 características · PC1 57.0% + PC2 16.4% + PC3 11.8% = 85.2% da variância



A–F · Correlações exatas por componente (arredondadas)

Característica	corr(variável, PC1)	corr(variável, PC2)	corr(variável, PC3)
A	+0.914	-0.077	-0.094
B	+0.853	-0.058	-0.156
C	-0.899	+0.095	+0.108
D	-0.804	+0.084	+0.158
E	+0.195	+0.968	-0.154
F	+0.601	+0.139	+0.786

No painel A, as setas representam correlações multiplicadas por 2,60 apenas para visualização; não têm a unidade dos scores.

No painel B, os vetores mantêm a escala verdadeira. O eixo PC3 é real (não jitter), e a classe não entra no ajuste PCA.

Dados sintéticos · sem dataset real, folds, GMM, F10 ou execução da pipeline. A inversão do sinal de um eixo PCA é equivalente.

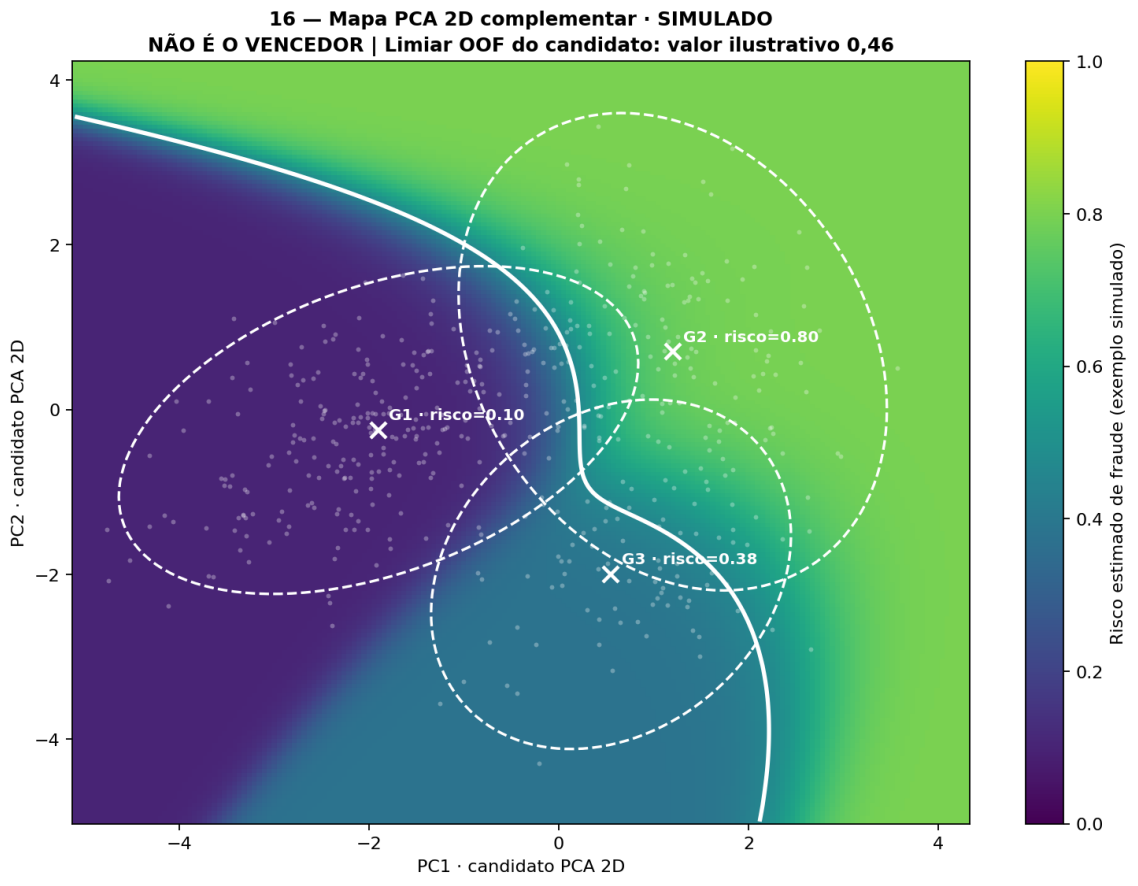
Nome do arquivo da pipeline: PCA_BIPLOT_3D.png. Máximo de setas controlado no YAML (max_setas); apenas a dimensionalidade selecionada é produzida.

GRÁFICO 16

Mapa 2D complementar

Só existe quando o vencedor OOF usa PCA 1D e outro candidato PCA 2D participa da mesma grade.

É um diagnóstico de um candidato NÃO VENCEDOR. Usa ajuste PCA 2D + GMM no desenvolvimento, risco do candidato e o seu próprio limiar MCC OOF. Não altera a escolha oficial nem utiliza F10.



Exemplo sintético: dados, gaussianas e limiar ilustrativos. Na pipeline o nome começa por 16_mapa_complementar_PCA2_GMM; um manifesto registra a natureza não oficial.