GRÁFICOS DE T-SNE

Catálogo visual e técnico para embeddings t-SNE

Este catálogo é separado dos catálogos de GMM e PCA e documenta como os gráficos de **t-SNE** devem ser apresentados. O foco está em visualização do embedding, preservação de vizinhanças locais e interpretação correta dos mapas gerados.

> **Regra central da projeção:** se o embedding tiver **1 dimensão**, a visualização preferencial deve ser um **histograma**; se tiver **2 dimensões**, usar um **mapa 2D**; se tiver **3 dimensões**, usar um **mapa 3D**.

GRÁFICO 2

Preservação de vizinhança — Trustworthiness vs. Perplexity

Este gráfico diagnostica o quanto o embedding t-SNE preserva as vizinhanças locais dos dados originais conforme variamos a **perplexity**. Ele ajuda a escolher um valor razoável desse hiperparâmetro antes de interpretar o mapa final.

O que ele representa

A métrica **trustworthiness** mede o quanto os vizinhos no embedding são consistentes com os vizinhos no espaço original.

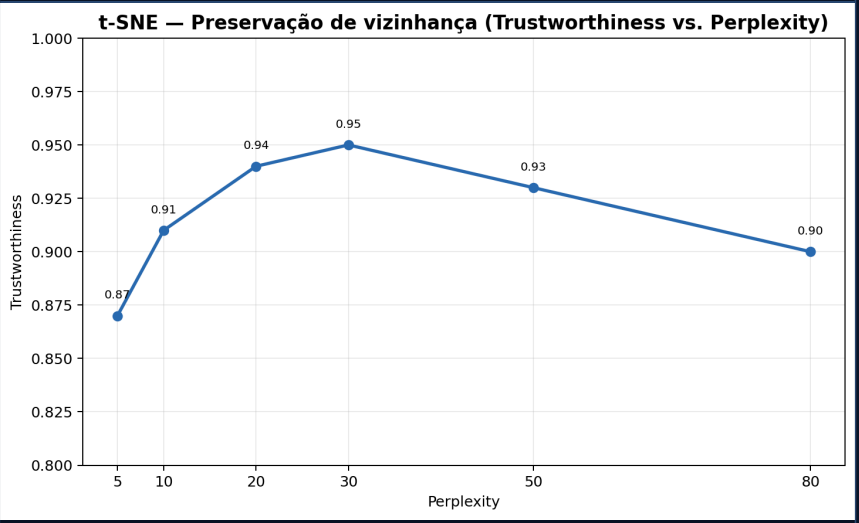
```
T(k) = 1 - □rac{2}{nk(2n-3k-1)} \sum_{i=1}^n
\sum_{j \in U_k(i)} (r(i,j)-k)
```

Quanto mais próximo de 1, melhor a preservação local.

Leitura correta

- O melhor ponto não é necessariamente o maior trustworthiness isolado; estabilidade e interpretabilidade também importam.
- Perplexity muito baixa pode fragmentar demais o embedding.
- Perplexity muito alta pode misturar estruturas locais distintas.
- Este gráfico é diagnóstico de qualidade local, não de separação de classes.

Trustworthiness vs. Perplexity



Exemplo ilustrativo com valores simulados. A curva mostra como a trustworthiness varia com a perplexity e

ajuda a escolher uma faixa de configuração para o embedding.

Instruções para a outra IA

1. Definir uma grade de valores de `perplexity` (por exemplo: 5, 10, 20, 30, 50, 80).
2. Para cada valor, ajustar o t-SNE e calcular a métrica `trustworthiness`.
3. Plotar a curva **trustworthiness vs. perplexity**.
4. Se necessário, repetir com mais de um `random_state` para avaliar estabilidade.
5. Destacar no texto qual valor ou faixa foi escolhida para o embedding final.

GRÁFICO 13

Mapa de embedding t-SNE

Este gráfico mostra a distribuição das observações no espaço t-SNE. O mapa pode ser colorido por classe, risco estimado, classe prevista ou gaussiana dominante, mas a regra de forma é fixa: **1D = histograma**, **2D = mapa 2D**, **3D = mapa 3D**.

1 dimensão → histograma **2 dimensões → mapa 2D**

3 dimensões → mapa 3D

O que ele representa

Os pontos projetados são as coordenadas do embedding t-SNE. A leitura principal é **local**: vizinhos próximos no embedding tendem a refletir relações de vizinhança do espaço original.

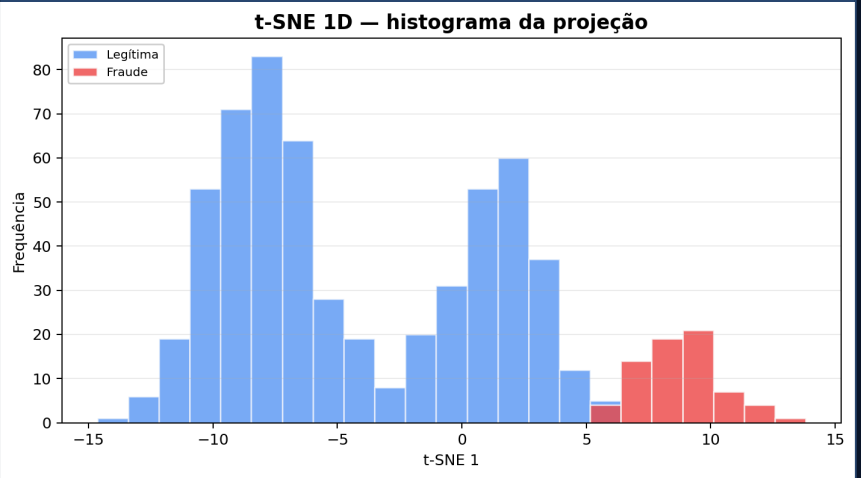
```
Y = tSNE(X_{prep};\, ext{perplexity},
ext{learning_rate}, ext{random_state})
```

Ele é excelente para ver agrupamentos, sobreposição e ilhas locais, mas não deve ser usado para inferir distâncias globais com rigor geométrico.

Regra metodológica obrigatória

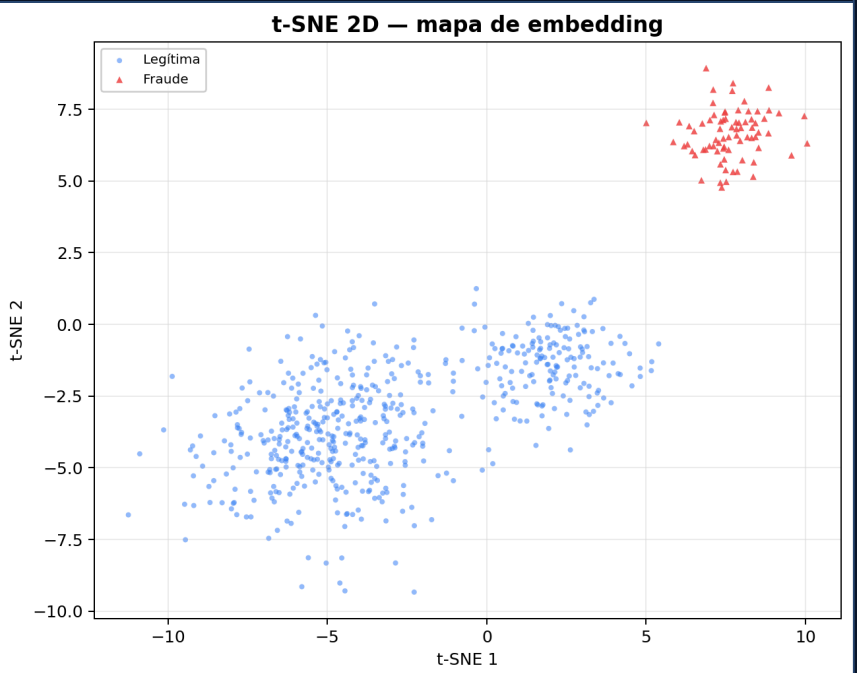
- Se o embedding final for 1D, usar **histograma**.
- Se o embedding final for 2D, usar **scatter 2D**.
- Se o embedding final for 3D, usar **scatter 3D**.
- Não forçar uma forma diferente da dimensionalidade realmente utilizada.
- Indicar claramente no subtítulo a dimensionalidade usada e a configuração principal do t-SNE.

Exemplo 1D — histograma do embedding



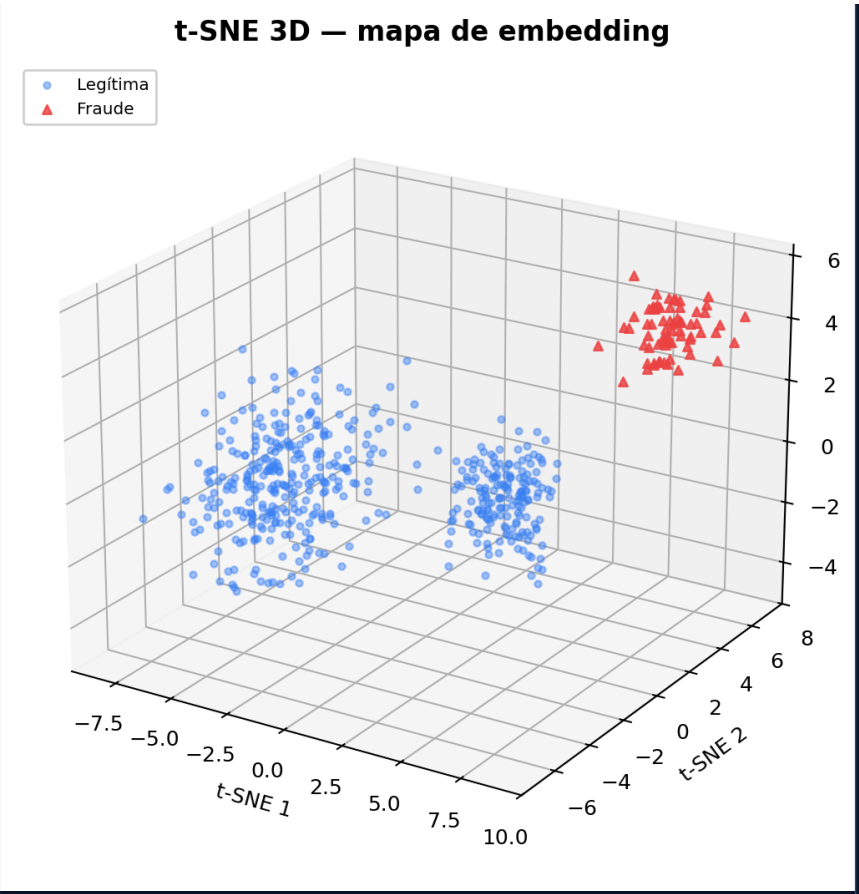
Quando o t-SNE retido possui **1 dimensão**, a visualização preferencial é um **histograma** do eixo **t-SNE 1**, podendo ser sobreposto por classe.

Exemplo 2D — mapa de embedding



Quando o t-SNE retido possui **2 dimensões**, a visualização correta é um **mapa 2D** em **t-SNE 1 × t-SNE 2**.

Exemplo 3D — mapa de embedding



Quando o t-SNE retido possui **3 dimensões**, a visualização correta é um **mapa 3D** em **t-SNE 1 × t-SNE 2 × t-SNE 3**.

Instruções para a outra IA

1. Receber ou calcular o embedding t-SNE no conjunto desejado.
2. Verificar `n_components` do embedding final.
3. Se `n_components = 1`, gerar **histograma** do eixo `t-SNE 1`.
4. Se `n_components = 2`, gerar **scatter 2D** em `t-SNE 1 × t-SNE 2`.
5. Se `n_components = 3`, gerar **scatter 3D** em `t-SNE 1 × t-SNE 2 × t-SNE 3`.
6. Permitir coloração por classe, risco, classe prevista ou gaussiana dominante, sem alterar a dimensionalidade do gráfico.

7. Explicitar que a leitura é local e que distâncias globais não devem ser superinterpretadas.

GRÁFICO 14

KL final e tempo da redução

Painel diagnóstico de otimização do embedding; não é métrica de classificação.

A implementação mostra KL final, tempo da redução, dimensionalidade, perplexity e quantidade de observações. Se KL não estiver disponível no redutor ajustado, deve ser indicado como indisponível.



Não é fornecida uma série histórica de KL por iteração: portanto, não se deve produzir uma curva de convergência inventada. O t-SNE é analisado pelo embedding, trustworthiness e indicadores próprios; AP/MCC vêm do OOF de classificação.

QUANDO O GRÁFICO APARECE

Somente em experimentos com método TSNE e redutor ajustado no desenvolvimento.
Saída: 14_tsne_diagnostico (gráfico e dados quando habilitados).
O F10 fica reservado e não compõe a otimização/seleção do embedding.